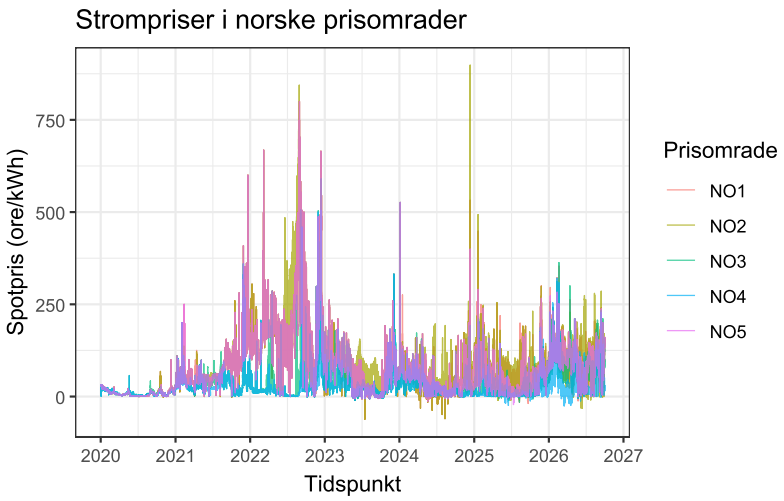
En kraftanalyse

Semesteroppgave i ECON3170/4170, Høst 2026

Kandidatnummer

25 oktober 2026

Sammendrag I dette prosjektet har jeg innhentet og bearbeidet store datasett fra ENTSO-E og NVE, og utviklet en strukturert kodeflyt for å analysere strømpriser i norske prisområder. Ved hjelp av lineære regresjonsmodeller undersøker jeg hvilke variabler som bidrar til å forklare og predikere prisutviklingen. Modellene oppnår best prediksjonsevne i NO1 og NO2, med test-R^2 på henholdsvis 0,52 og 0,60, der europeiske strømpriser er sentrale forklaringsvariabler. I NO3 presterer modellen dårligere enn en enkel modell som predikerer gjennomsnittsprisen, blant annet fordi den ikke fanger opp den kraftige prisøkningen i testperioden. Prosjektet har gitt erfaring med API-er, effektiv databehandling, kodeorganisering og statistisk modellering.



Figur 1: Utvikling i strømpriser i norske prisområder fra 2020 til 2026.

1 Motivasjon for prosjektet

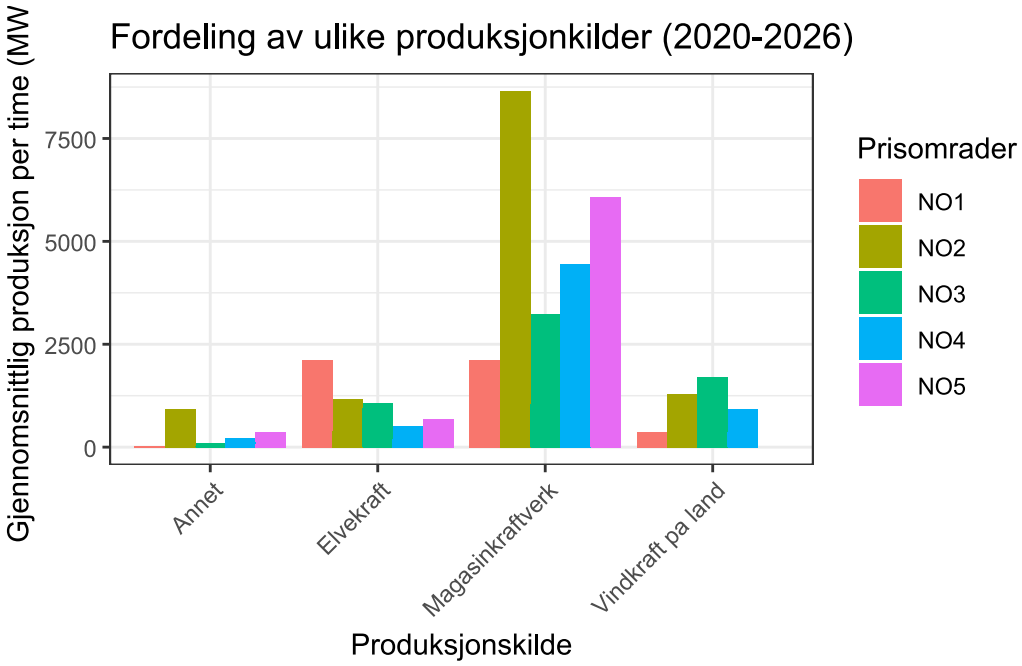
Norge har historisk hatt svært lave strømpriser, og frem til 2020 lå spotprisen mellom 20 - 45 øre/kWh (ekslusive nettleie og avgifter).[1] Dette har ført til at mye kraftkrevende industri er etablert i Norge (aluminumumskraftverk), og husholdninger har vært vant til relativt strømregninger, til tross for kalde vintre i dårlig isolerte hjem og oppvarmede badebaseng.

Prissjokket i 2021–2022 satte derfor strømprisene på den politiske dagsordenen, ettersom de kraftige prisøkningene rammet både husholdninger og bedrifter hardt. Figur 1 viser utviklingen i spotprisene i de fem norske prisområdene fra 2020 til 2026. Figuren viser en betydelig prisøkning i alle prisområdene, men med tydelige geografiske forskjeller. Prisøkningen var særlig kraftig i NO1, NO2 og NO5, mens prisene i NO3 og NO4 gjennomgående var lavere og mer stabile. Utenlandskablene ble raskt fremstilt som en folkefiende i den norske offentligheten. Motstanden ble ikke bare drevet av høye strømpriser, men også av en opplevelse av at Norge eksporterte ren, fornybar vannkraft til Europa, samtidig som norske forbrukere måtte betale mer for strømmen, og at vi fikk skitten, forurenset kullkraft i stikkkontakten.

Tabell 1: Beskrivelse av de ulike prisområdene

Prisomrade	Geografisk omrade	Sentrale kjennetegn
NO1	Ostlandet	Hoyt forbruk og stor befolkning.
NO2	Sorvestlandet	Mye vannkraft og flere utenlandsforbindelser.
NO3	Midt-Norge	Mye vannkraft og begrenset overforing sorover.
NO4	Nord-Norge	Mye vannkraft og relativt lavt forbruk.
NO5	Vestlandet	Mye vannkraft og varierende produksjon.

I tillegg til spotprisen varierer kraft-produksjonen og forbruk mellom prisområdene, som vist i Tabell 1. Figur 2 viser fordelingen av kraftproduksjonen i de ulike prisområdene, og det er tydelig at vannkraft utgjør en betydelig del produksjonen. Vannkraft med magasiner skiller seg fra mange andre fornybare energikilder ved at produksjonen til en viss grad kan reguleres ved å styre hvor mye vann som slippes gjennom turbinene.



Figur 2: Sammensetning av kraftprosuksjonen i ulike prisområder

1.1 Om prosjektet

Prosjektet har en utforskende datavitenskapelig tilnærming. Innledningsvis kartlegger jeg og samler inn data for et bredt utvalg av mulige forklaringsvariabler for strømprisen; vannkraftsproduksjon, strømforbruk i den enkelte prissone, magasinfylling, tilsig, europeiske priser og nedbør. Dataene bearbeides og analyseres utforskende for å undersøke datakvalitet, tidsmessig dekning og mulige sammenhenger mellom variablene. Formålet er å kartlegge hvilke data som egner seg for videre analyse, og å etablere et datagrunnlag for statistisk modellering. Deretter utvikles en regresjonsmodell som trenes på historiske data for å predikere fremtidige strømpriser.

2 Datainnsamlingen

Datainnsamlingen har vært en stor del av prosjektet. Jeg har hentet inn data fra fire ulike API-er (grensesnitt som gjør det mulig for programmer å hente data direkte fra andre systemer), med ulike dataformater. Siden dataene har høy tidsoppløsning, fra 15-minuttersintervaller til dagsoppløsning, er datamengdene store. Dette har stilt krav til strukturert og effektiv kode for å hente ut og bearbeide dataene.

I mappen *Kilder* gjennomføres API-kallene og dataen bearbeides til rds-filer, før de lagres i *Datasett*. Når jeg senere utfører analyser på datasettene, hentes de ut som RDS-filer, slik at de tid- og resusskrevende API-kallene ikke gjennomføres flere ganger enn nødvendig. Prosjektet bruker to kilder for data, ENTSO-E [2] og NVE[3], som leverer API-ene i to ulike formater.

2.1 Beskrivelse av kildene

Kilde	Forklaring av kilden	Format
ENTSO-E	Europeisk datasett for strømpriser (spotpriser i kraftmarkedet), kraftflyt og produksjon fordelt på produksjonstype.	XML
NVE	Norges vassdrags- og energidirektorat. Magasinstatistikk (fyllingsgrad) og tilsig.	JSON

2.1.a ENSTSO-E (XML)[1]

Dataene fra ENTSO-E leveres i XML-format, et tekstbasert format der informasjonen er organisert i en hierarkisk trestruktur. XML-responsen fra API-et leses inn og parses for å gjøre innholdet tilgjengelig for videre behandling. Ved hjelp av XML-parsing identifiseres relevante elementer og attributter som inneholder informasjon om blant annet tidspunkt, spotpriser (A44), produksjon og forbruk (A16).

Datainnsamlingen er strukturert modulbasert, med separate filer for ulike deler av prosessen. Denne organiseringen gjør koden mer oversiktlig og vedlikeholdbar ved å samle funksjonalitet knyttet til ulike datakilder og datatyper i egne moduler. Det bidrar også til å avgrense kompleksiteten og gjør det enklere å videreutvikle og feilsøke de enkelte delene av datainnsamlingen uavhengig av hverandre. Siden dataene fra ENTSO-E leveres i en hierarkisk XML-struktur og behandles som nestede lister, kan den samme overordnede kodestrukturen gjenbrukes for flere datatyper, blant annet spotpriser og kraftproduksjon. Selv om innholdet og enkelte elementer varierer, følger innlesing, parsing og uttrekk av data de samme grunnleggende prinsippene.

De relevante dataene hentes deretter ut av XML-strukturen, bearbeides og samles i en tibble, før de som nevnt lagres som RDS-filer i *Datasett*.

Ettersom datamengden er stor, med rundt én million observasjoner per datasett i perioden 2020–2026, kan det oppstå tidsavbrudd dersom hele perioden hentes ut i ett enkelt API-kall. For å redusere denne risikoen deles tidsperioden derfor opp i månedlige intervaller. En løkke henter deretter data for én måned om gangen. De månedlige datasettene settes sammen til én samlet tibble ved hjelp av `bind_rows()`, før det ferdige datasettet lagres for videre analyse. Ved å hente data én måned om gangen og lagre hovedtibbelen fortløpende, reduserer vi risikoen for å miste allerede innhentede data dersom et API-kall feiler. Dersom et API-kall feiler, fortsetter innhentingen med neste måned uten at tidligere innhentede data går tapt.

2.1.b NVE (JSON)[2]

Dataene fra NVE leveres i JSON-format (*JavaScript Object Notation*), et tekstbasert format der informasjonen er strukturert i nøstede objekter og arrayer. Dataene leses inn og parses slik at de kan bearbeides videre og organiseres i en tibble.

[1] Se *Kilder/henting av data fra ENTSO-E* for den modulbaserte implementasjonen, der API-kallene er organisert i separate, gjenbrukbare filer.

[2] Se *Kilder/henting_av_data_NVE* for uthenting av tilsigsdata og magaisnfylling.

Dataene fra NVE er tilgjengelige på dags- eller ukesformat, noe som gjør det mulig å hente data for hele perioden 2020 - 2026 i ett API-kall. Ved innhenting av tilsig er det imidlertid rundt 650 målestasjoner som skal behandles, noe som øker risikoen for at API-kallene overskrider tidsbegrensningen. For å redusere denne risikoen benyttes derfor samme fremgangsmåte som for ENTSO-E, der dataene hentes ut én målestasjon om gangen og lagres fortløpende underveis. Dataene fra de ulike målestasjonene samles deretter i én tibble ved hjelp av `bind_rows()`. Dette gjør innhentingen mer robust, ettersom en eventuell feil i et senere API-kall ikke fører til at tidligere innhentet data går tapt.

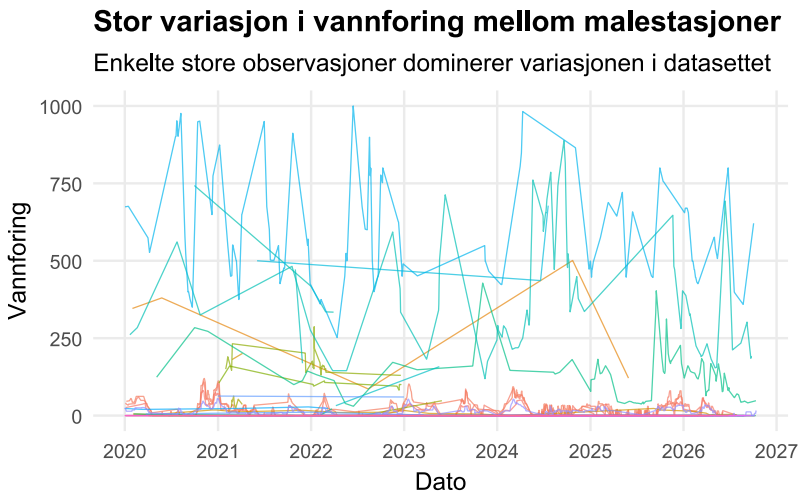
2.2 Bruk at dtplyr

Datasettene inneholder opptil 1,5 millioner datapunkter. For å effektivisere behandlingen av de store datamengdene benyttes dtplyr, som oversetter dplyr-operasjoner til mer effektive data.table-operasjoner. Dette bidrar til raskere databehandling og redusert minnebruk.

2.3 Utelating av forklaringsvariabler

Ettersom prosjektet har en utforskende tilnærming og undersøker et bredt utvalg av mulige forklaringsvariabler, ble også britisk strømpris, nedbør og tilsig vurdert inkludert i regresjonsmodellene. Britisk strømpris var imidlertid bare tilgjengelig for 2020. Inkludering av denne variabelen ville derfor ha redusert datagrunnlaget betydelig for NO3 (prissonen som har utenlandskabler til Storbritannia).

Ettersom magasinkraftverk er avhengige av nedbør og tilsig for å opprettholde magasinfyllingen, ble det forsøkt å inkludere hydrologiske data i analysen. Formålet var å undersøke om informasjon om vanntilgangen kunne bidra til å forklare variasjoner i strømprisene. Det viste seg imidlertid å være utfordrende å identifisere målestasjoner som var representative for de aktuelle vannmagasinene, og å koble målingene til magasinene på en hensiktsmessig måte. I tillegg var det betydelig variasjon i målt vannføring mellom målestasjonene. Som vist i figur Figur 3 varierer vannføringen på tvers av målestasjonene, mens figur Tabell 2 illustrerer den store spredningen i de observerte verdiene. Variasjonen gjorde det vanskelig å skille mellom reelle hydrologiske forskjeller og støy i målingene, og dermed også å avgjøre hvordan dataene burde aggregeres for å gi et representativt mål på tilsiget i de ulike prisområdene. På bakgrunn av dette, er tilsigsdataene utelatt som forklaringsvariabel i den endelige modellen.



Figur 3: Støy i hydrologiske forhold

Tabell 2: Observasjoner fordelt på vannføringsintervaller

Kategori	Nedre grense	Ovre grense	Antall observasjoner
Lav	−10000.000	1.947	528100
Lav-middels	1.947	11.724	396075
Middels-hoy	11.724	62.993	264050
Hoy	62.994	946585099999999996136486.000	132025

3 Databehandling og regresjonsanalyse

3.1 Valg av modell

Det finnes flere maskinlæringsmetoder for å modellere kontinuerlige variabler, blant annet Random Forest, XGBoost, OLS og LASSO. Trebaserte metoder som Random Forest og XGBoost kan fange opp komplekse og ikke-lineære sammenhenger, mens lineære regresjonsmodeller som OLS gir koeffisienter som er enklere å tolke.

Formålet med prosjektet er å undersøke overordnede sammenhenger mellom strømpriser og mulige forklaringsvariabler, snarere enn å maksimere modellens prediksjonsnøyaktighet. Derfor velger vi å sette opp en linjær regresjonsmodell, som gjør det mulig å undersøke sammenhengen mellom hver forklaringsvariabel og strømprisen, gitt at de øvrige variablene i modellen holdes konstante. Den relativt enkle modellstrukturen gjør resultatene lettere å tolke, men begrenser samtidig modellens evne til å fange opp ikke-lineære sammenhenger og ekstreme prisbevegelser.

Vi kontruerer dermed en linjær regresjonsmodell med normalfordelte feilledd på formen

For hvert prisområde j og tidspunkt t estimeres følgende lineære regresjonsmodell:

$$P_{t,j} = \beta_{0,j} + \beta_{1,j} F_{t,j} + \beta_{2,j} M_{t,j} + \beta_{3,j} V_{t,j} + \varepsilon_{t,j},$$

for prisområdene NO3, NO4 og NO5. For NO1 og NO2 inkluderes også europeisk strømpris som forklaringsvariabel:

$$P_{t,j} = \beta_{0,j} + \beta_{1,j}F_{t,j} + \beta_{2,j}M_{t,j} + \beta_{3,j}V_{t,j} + \beta_{4,j}E_t + \varepsilon_{t,j}.$$

Her betegner $P_{t,j}$ strømprisen i prisområde j på tidspunkt t, $F_{t,j}$ strømforbruket, $M_{t,j}$ produksjonen fra magasinkraftverk, $V_{t,j}$ øvrige produksjonsvariabler og E_t europeisk strømpris. Konstantleddet betegnes med $\beta_{0,j}$, mens $\hat{\beta}_{1,j}..., \hat{\beta}_{4,j}$ er regresjonskoeffisientene. Det normalfordelte feilleddet betegnes med $\varepsilon_{t,j} \overset{\text{iid}}{\sim} N(0, \sigma^2)$.

Modellen antar at feilleddene $\varepsilon_{t,j} \sim N(0, \sigma^2)$. Antagelsen om konstant varians innebarer at variasjonen i feilleddene er den samme pa tvers av tidspunkter og prisomrader. Det er mulig at denne antagelsen ikke holder for strompriser, men testing for heteroskedastisitet ligger utenfor prosjektets omfang.

3.2 Valg av forklaringsvariabler[3]

For å gjennomføre analysen ønsker vi å sammenstille alle datakildene i én felles tibble. Siden dataene har ulik tidsoppløsning, må de først bearbeides slik at de kan kobles sammen på en konsistent måte. Strømpriser, forbruk og kraftproduksjon aggregeres til én observasjon per time og prisområde. Dette innebærer at dersom det finnes flere målinger innenfor samme time, beregnes gjennomsnittet. Tilsig og magasinfylling behandles separat og aggregeres til én observasjon per dag og prisområde. Deretter sammenstilles datasettene ved hjelp av left_join(), med norske strømpriser som utgangspunkt.

3.2.-.a Manglende observasjoner og klargjøring av data[4]

Før vi trener modellen på datasettet, fjernes observasjoner med manglende eller ugyldige verdier separat for hvert prisområde. Dette er nødvendig, da regresjonsmodellene krever gyldige verdier for både den avhengige variabelen og samtlige forklaringsvariabler. Som vist i Tabell 3, beholdes omtrent 99 % av observasjonene i samtlige prisområder etter filtreringen.

Tabell 3: Antall observasjoner før og etter rensing per prisområde.

Prisomrade	Andel beholdt	Observasjoner i testsettet	Observasjoner i treningsettet
NO1	99.3%	11,575	46,298
NO2	99.0%	11,523	46,092
NO3	99.2%	11,536	46,144
NO4	99.3%	11,400	45,599
NO5	99.0%	11,488	45,952

Dataene deles kronologisk ved hjelp av `initial_time_split()`, der de første 80 prosentene av observasjonene utgjør treningssettet, mens de resterende 20 prosentene utgjør testsettet, som vist i Tabell 3.

[3] Se *analyse/analyse_steg4/ferdig_til_tibble.R*

[4] Se *analyse/analyse_steg4/analysen_vi_skal_bruke.R* for hele scriptet.

For tidsseriedata er en kronologisk splitting hensiktsmessig, da modellene estimeres på historiske observasjoner og evalueres på senere data. Dermed unngår man at fremtidige observasjoner brukes til å predikere fortidige verdier. Ettersom modellene for de ulike prissonene estimeres separat, varierer delingsdatoen noe, som følge av ulik datadekning og filtrering av observasjoner. For å angi et felles tidspunkt for skillet mellom trenings- og testsettet, beregnes derfor gjennomsnittet av delingsdatoene. Dette tilsvarer omtrent tidspunktet der 80 prosent av observasjonene er passert.

```
[1] "Splitten skjer 2025-05-17"
```

Da forklaringsvariablene har ulik størrelsesorden, standardiseres de for å gjøre dem lettere å sammenligne. Dette gjøres ved hjelp av funksjonen `standardiser(data)`, som sentrerer hver variabel rundt gjennomsnittet og skalerer den med standardavviket. Variablene får dermed gjennomsnitt lik null og standardavvik lik én, slik at de uttrykkes på samme skala uavhengig av opprinnelig måleenhet.

```
  standardiser <- function(data) {
    data |>
      mutate(
        across(all_of(variabler),~
                 (.x - gjennomsnitt[[cur_column()]])/
standardavvik[[cur_column()]]
               ))}
```

Modelleringen gjennomføres i `tidymodels`, der en workflow kombinerer regresjonsmodellen med en formel som spesifiserer hvilke forklaringsvariabler som inngår. Det estimeres separate lineære regresjonsmodeller med minste kvadraters metode (OLS) for hvert av de fem norske prisområdene. Modellene tilpasses i en løkke, der det tas hensyn til at NO1 og NO2 inkluderer europeisk strømpris som forklaringsvariabel, mens denne variabelen utelates for NO3, NO4 og NO5.

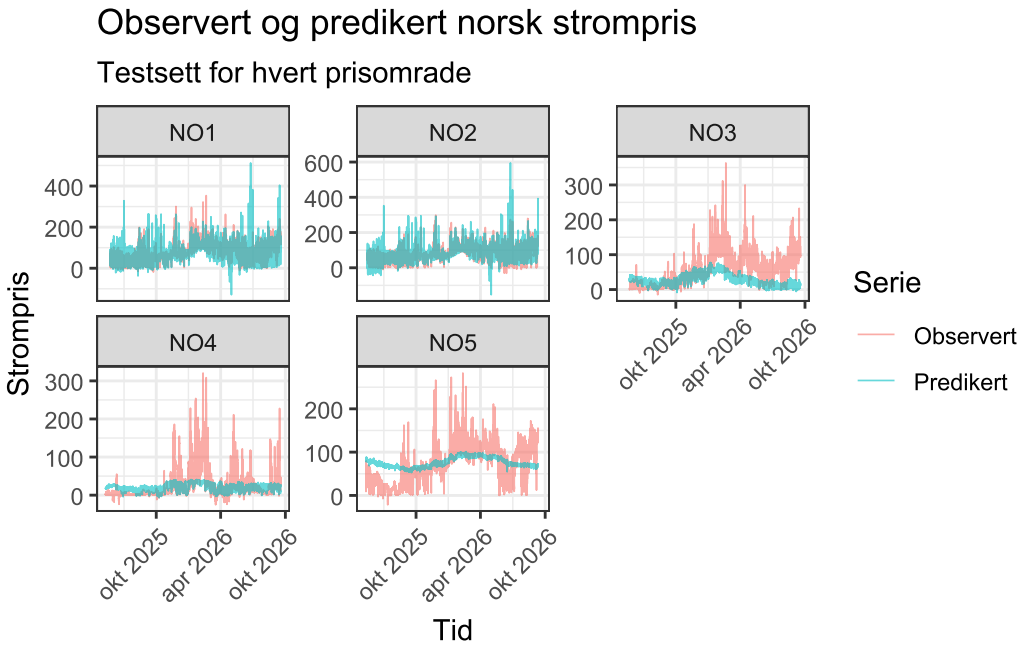
De tilpassede modellene brukes til å predikere strømprisene i testsettet. Prediksjonene transformeres deretter fra standardisert format tilbake til den opprinnelige prisskalaen, slik at de kan sammenlignes med de observerte strømprisene. Modellens prediksjonsevne evalueres ved hjelp av MSE og R^2, beregnet på testsettet og ikke treningssettet som modellen har tilpasset seg til. R^2 beregnes som $R^2 = \frac{SSR}{SST}$, der SR er summen av kvadrerte prediksjonsfeil i testsettet, mens SST er summen av kvadrerte avvik mellom de observerte prisene i testsettet og gjennomsnittsprisen i samme periode, altså fra mai 2025.

Tabell 4: Modellens prediksjonsevne i testsettet

Prissone	MSE	R^2
NO1	763.0732	0.5274
NO2	555.9463	0.6040
NO3	2338.7337	−0.2656
NO4	869.6404	0.2602
NO5	1252.3460	0.2365

Som vist i Tabell 4 oppnår modellene for NO1 og NO2 R^2-verdier på henholdsvis 0,52 og 0,60. Dette gjenspeiles i Figur 4, der de predikerte prisene i stor grad følger utviklingen i de observerte prisene. For NO4 og NO5 ligger prediksjonene derimot nær gjennomsnittsnivået og fanger i liten grad opp prisvariasjonene. Modellen for NO3 presterer svakest, med en negativ R^2-verdi på −0,26. Dette innebærer at modellens kvadrerte prediksjonsfeil er 26 prosent høyere enn for en referansemodell som predikerer gjennomsnittsprisen i testperioden.

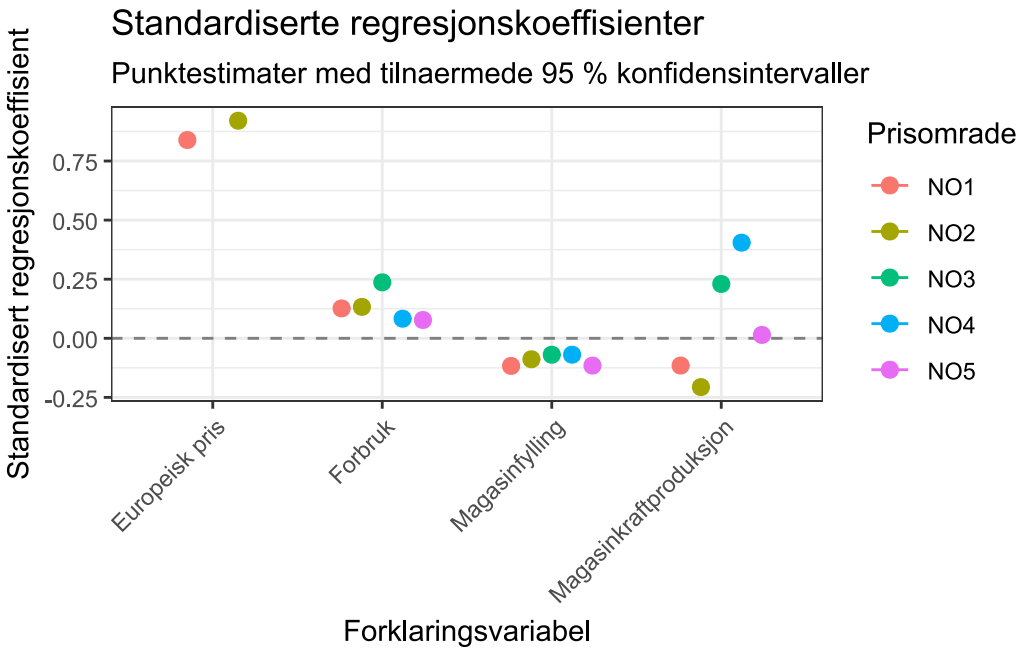
En viktig forklaring på de svake resultatene er at strømprisene steg i NO3 etter mai 2025, uten at modellen klarte å fange opp denne utviklingen. Modellene er basert på historiske sammenhenger og tar ikke høyde for nye markedsforhold som ikke er representert i treningsdataene. Dermed viderefører de i liten grad prisoppgangen i prediksjonene. Dette illustrerer en sentral svakhet ved å predikere langt frem i tid basert på dagens kunnskapsgrunnlag: Når markedsforholdene endrer seg, kan historiske sammenhenger bli mindre representative, og prediksjonsevnen svekkes betydelig.



Figur 4: Predikerte verdier mot observerte verdier

3.3 Regresjonskoeffisienter og sammenhenger

For å undersøke hvilke forklaringsvariabler som har sterkest sammenheng med strømprisen, henter vi ut de standardiserte regresjonskoeffisientene fra hver modell. Koeffisientene angir hvor mange standardavvik den predikerte strømprisen endres når en forklaringsvariabel øker med ett standardavvik, gitt at de øvrige variablene holdes konstante.



Figur 5: Plott av standardiserte regresjonskoefesienter

Figur 5 viser de estimerte koeffisientene med tilnærmede 95 prosent konfidensintervaller. Den europeiske strømprisen har en standardisert koeffisient på omtrent 0,8 i NO1 og NO2, noe som indikerer en sterk positiv sammenheng med norske strømpriser i disse områdene. Forbruk har gjennomgående positive, men svakere koeffisienter i intervallet $[0, 0.25]$ med de laveste verdiene i NO4 og NO5. Magasinfylling har en svak negativ sammenheng med strømprisen, mens magasinkraftproduksjon har en positiv sammenheng i NO3 og NO4, en tilnærmet null sammenheng i NO5 og en negativ sammenheng i NO1 og NO2.

Resultatene må tolkes med forsiktighet, ettersom NO1 og NO2 inkluderer europeisk strømpris som forklaringsvariabel, mens NO3–NO5 ikke gjør det. Prisene i NO3 begynte dessuten å stige etter at modellen var tilpasset, noe som begrenser modellens evne til å predikere den videre prisutviklingen. Analysen har en utforskende datavitenskapelig tilnærming og er ikke en økonometrisk analyse av de underliggende økonomiske mekanismene. Koeffisientene brukes derfor til å undersøke statistiske sammenhenger og mønstre i dataene, og kan ikke uten videre tolkes som kausale effekter.

4 Konklusjon

Prosjektets hovedfunn er at europeiske strømpriser er en sentral forklaringsvariabel for prisutviklingen i NO1 og NO2, der modellene oppnår test-R^2 på henholdsvis 0,52 og 0,60. For NO3, NO4 og NO5 er prediksjonsevnen betydelig svakere, og modellene fanger i liten grad opp de observerte prissvingningene. Særlig viser den negative R^2-verdien for NO3 at modellen presterer dårligere enn en enkel prediksjon basert på gjennomsnittsprisen i testperioden. Resultatene viser dermed at en lineær modell med de valgte forklaringsvariablene fungerer bedre i noen prisområder enn i andre. Prosjektet har også vist hvor viktig datakvalitet, representativitet og valg av forklaringsvariabler er for å utvikle modeller som kan beskrive og predikere strømpriser.

Bruk av AI

Jeg har brukt AI som et hjelpemiddel i programmeringsarbeidet, særlig ved innhenting av data fra ENTSO-E og NVE. API-ene har omfattende dokumentasjon og komplekse strukturer, og det er svært tid- og resusskrevende å å finne riktig syntaks og utforme dataforespørsler. AI har derfor vært nyttig for å forstå API-ene, utforme forespørsler og feilsøke kode.

Jeg har ikke brukt AI-agenter til verken API-kallene eller utforming av analysen. All kode er gjennomgått av meg, og jeg har selv arbeidet med optimalisering, debugging og strukturering av koden. Jeg har dermed hatt kontroll over både datainnhentingen og den videre analysen, og kan derfor forstå og forklare all kode i prosjektet.

Bibliografi

[1] SSB, «Hva koster det å produsere vannkraft?». Åpnet: 30. september 2026. [Online]. Tilgjengelig på: https://www.ssb.no/energi-og-industri/energi/statistikk/elektrisitetspriser

[2] ENTSO-E, «Transparency Platform API Guide». Åpnet: 25. oktober 2026. [Online]. Tilgjengelig på: https://transparency.entsoe.eu/content/static_content/Static%20content/web%20api/Guide.html

[3] Norges vassdrags- og energidirektorat (NVE), «Hydrologiske data». Åpnet: 25. oktober 2026. [Online]. Tilgjengelig på: https://api.nve.no/doc/hydrologiske-data/