Første utkast for kildebeskrivelse

kandidatnummer

13 oktober 2026

1 Datainnsamlingen

Datainnsamlignen har vært en stor del av prosjektet, da jeg har hentet data fra fire ulike API-er, levert i ulikt formater. Da dataen har høy tidsoppløsning (15 minutter til dagsoppløsning) er dette svært store datasett, som krever strukturert og effektiv kode å hente ut.

I mappen *Kilder* gjennomføres API-kallende, før de lagres som RDS-filer i *Datasett*. Når vi skal analysere datasettene henter vi RDS-filene ut fra *Datasett*, slik at vi unngår å gjøre det tid- og resusskrevende API-kallet flere ganger enn nødvendig.

I dette prosjeket har jeg brukt to kilder, ENSTO-E og NVE.

Kilde	Datasett	Format
ENTSO-E	Europeisk datasett for strømpriser (spotpriser i kraftmarkedet), kraftflyt og produksjon fordelt på produksjonstype.	XML
NVE	Norges vassdrags- og energidirektorat. Magasinstatistikk (fyllingsgrad) og tilsig.	JSON

1.1 ENTSTO-E

1.1.a Formatet til API-et (XML)

Dataene fra ENTSTO-E leveres i XML-format, som er et tekstbasert format der informasjonen er organisert i nestede elementer. Informasjonen må derfor hentes ut stegvis og bearbeides før de settes sammen i en tibble. Hvert prisområde identifiseres med en egen EIC-kode (*Energy Identification Code*), som må hentes eller defineres for å kunne etterspørre data for riktig område.

«API-nøkkel» -> «EIC-kode» -> «Hente data» -> «Bearbeide XML» -> «Sette sammen tibble» -> «Lagre data»

1.1.b Behandling av store datasett

Ettersom datamengden er stor, med rundt én million observasjoner per datasett i perioden 2020–2026, kan det oppstå tidsavbrudd dersom hele perioden hentes ut i ett enkelt API-kall. For å redusere denne risikoen deles tidsperioden derfor opp i månedlige intervaller. En løkke henter

deretter data for én måned om gangen. De månedlige datasettene settes sammen til én samlet tibble ved hjelp av `bind_rows()`, før det ferdige datasettet lagres for videre analyse.

```
  maaneder <- seq(
    from = as.Date(format(start_dato, "%Y-%m-01")),
    to = as.Date(format(slutt_dato, "%Y-%m-01")),
    by = "month")
```

1.2 NVE

Fyllingsgraden i vannmagasinene rapporteres ukentlig, mens tilsiget måles på dagsnivå. For å håndtere de ulike tidsoppløsningene og sikre en effektiv datauthenting hentes tilsiget separat for hver målestasjon. Dataene fra hver stasjon lagres i en egen fil, slik at innhentingen kan gjenopptas uten å måtte hente alle dataene på nytt dersom en enkelt forespørsel feiler.