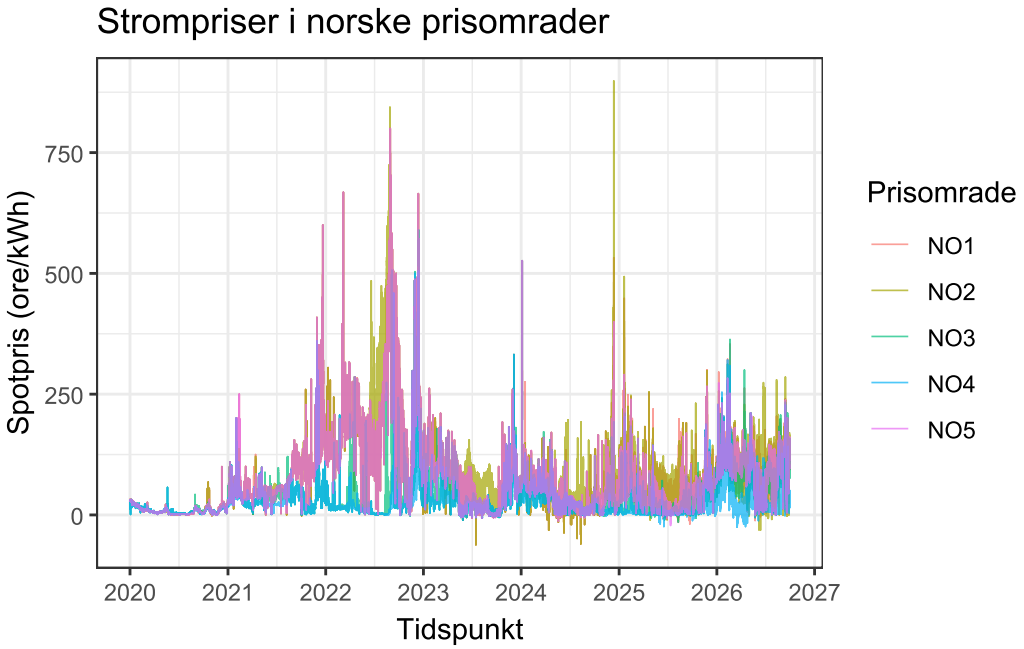
Første utkast for kildebeskrivelse

kandidatnummer

19 oktober 2026

1 Motivasjon

Norge har historisk hatt svært lave strømpriser, og frem til 2020 lå spotprisen mellom 20 - 45 øre/kWh (ekslusive nettleie og avgifter).[1] Dette har ført til at mye kraftkrevende industri er etablert i Norge (aluminumumskraftverk), og husholdninger har vært vant til relativt lave strømregninger, til tross for kalde vintre i dårlig isolerte hjem.



Figur 1: Utvikling i strømpriser i norske prisområder fra 2020 til 2026.

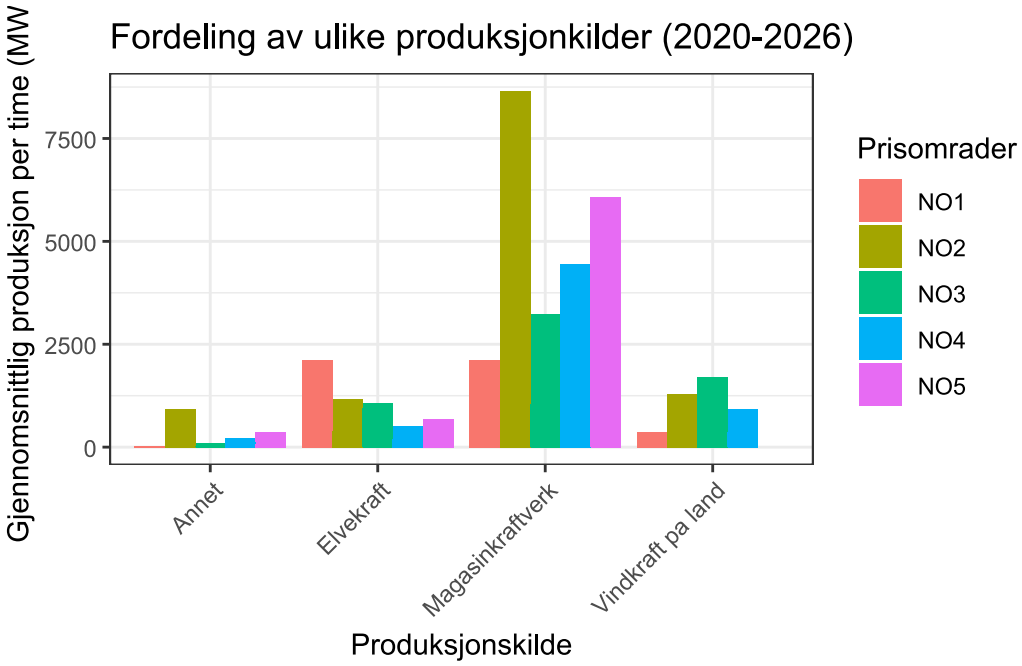
Strømprissjokket i 2021–2022 satte derfor strømprisene på den politiske dagsordenen, ettersom de kraftige prisøkningene rammet både husholdninger og bedrifter hardt. Figur 1 viser utviklingen i spotprisene i de fem norske prisområdene fra 2020 til 2026. Figuren viser en betydelig prisøkning i alle prisområdene, men med tydelige geografiske forskjeller. Prisøkningen var særlig kraftig i NO1, NO2 og NO5, mens prisene i NO3 og NO4 gjennomgående var lavere og mer stabile. Disse forskjellene reiser spørsmål om hvilke faktorer som kan forklare variasjonen i strømprisene

mellom prisområdene og over tid. Tabell 1 gir en rask oversikt over de ulike prisområdene, og hva som kjennetegner dem.

Tabell 1

Prisomrade	Geografisk omrade	Kjennetegn
NO1	Østlandet, inkludert Oslo-området	Hoyt forbruk og tett befolkning. Lite egen strøm produksjon
NO2	Sorvestlandet	Mye vannkraft og overføringskabler forbindelser til utlandet (Danmark, Storbritannia og Tyskland)
NO3	Midt-Norge, innkludert Trondheim	Mye vannkraft, men begrenset overforingskapasitet mot sor. Relativt høyt forbruk, grunnet mange inbyggere og mye industri
NO4	Nord-Norge	Mye vannkraft og relativt lavt forbruk, grunnet få mennesker. Noe kraftkrevende industri etablerer seg, grunnet de lave prisene
NO5	Vestlandet, innkludert Bergen	Vestland og omradet rundt Bergen. Mye vannkraft og store variasjoner i produksjon.

I tilegg til spotprisen, varierer også kraftproduksjonen mellom prisområdene, både når det gjelder produksjonskilder og muligheten til å regulere produksjonen. Som vist i Figur 2 utgjør vannkraft en betydelig del av kraftproduksjonen i alle prisområdene. Vannkraft med magasiner skiller seg fra mange andre fornybare energikilder ved at produksjonen kan reguleres ved å styre hvor mye vann som slippes gjennom turbinene.



Figur 2: Sammensetning av kraftprosuksjonen i ulike prisområder

Prosjektet har en utforskende datavitenskapelig tilnærming. Innledningsvis kartlegges et bredt utvalg av mulige forklaringsvariabler for strømprisen, blant annet kraftproduksjon, strømforbruk, magasinfylling, tilsig og nedbør. Dataene bearbeides og analyseres utforskende for å undersøke datakvalitet, tidsmessig dekning og mulige sammenhenger mellom variablene. Formålet er å kartlegge hvilke data som er egnet for videre analyse, og å etablere et grunnlag for statistisk modellering, der jeg skal bruke regresjon for å trene en modell for å predikere strømprisen.

2 Datainnsamlingen

Datainnsamlignen har vært en stor del av prosjektet, da jeg har innhentet data fra fire ulike API-er, levert i ulikt formater. Da dataen har høy tidsoppløsning (15 minutter til dagsoppløsning) er dette svært store datasett, som krever strukturert og effektiv kode å hente ut.

I mappen *Kilder* gjennomføres API-kallene og dataen bearbeides til rds-filer, før de lagres i *Datasett*. Når jeg senere utfører analyser på datasettene, hentes de ut som RDS-filer, slik at de tid- og resusskrevende API-kallene ikke gjennomføres flere ganger enn nødvendig. Prosjektet bruker to kilder for data, ENTSO-E og NVE, som leverer API-ene i to ulike formater.

2.1 Beskrivelse av kildene

Kilde	Forklaring av kilden	Format
ENTSO-E	Europeisk datasett for strømpriser (spotpriser i kraftmarkedet), kraftflyt og produksjon fordelt på produksjonstype.	XML

Kilde	Forklaring av kilden	Format
NVE	Norges vassdrags- og energidirektorat. Magasinstatistikk (fyllingsgrad) og tilsig.	JSON

2.1.a ENSTSO-E (XML)[1]

Dataene fra ENTSO-E leveres i XML-format, et tekstbasert format der informasjonen er organisert i en hierarkisk trestruktur. XML-responsen fra API-et leses inn og parses for å gjøre innholdet tilgjengelig for videre behandling. Ved hjelp av XML-parsing identifiseres relevante elementer og attributter som inneholder informasjon om blant annet tidspunkt, spotpriser (A44), produksjon og forbruk (A16).

For å hente data fra et bestemt prisområde benyttes en tilhørende EIC-kode (*Energy Identification Code*), som identifiserer området i kraftmarkedet. API-forespørselen spesifiserer dermed både hvilken EIC-kode og hvilken type data som skal hentes ut.

Datainnsamlingen er organisert modulbasert, der ulike deler av prosessen er fordelt på separate filer. Dette gjør koden mer oversiktlig og avgrenser kompleksiteten ved å samle funksjonalitet for ulike datakilder og datatyper i egne moduler. Siden dataene fra ENTSO-E leveres i en hierarkisk XML-struktur og behandles som nestede lister, kan den samme overordnede kodestrukturen gjenbrukes for flere datatyper, blant annet spotpriser og kraftproduksjon. Selv om innholdet og enkelte elementer varierer, følger innlesing, parsing og uttrekk av data de samme grunnleggende prinsippene.

De relevante dataene hentes deretter ut av XML-strukturen, bearbeides og samles i en tibble, før de som nevnt lagres som RDS-filer i *Datasett*.

Ettersom datamengden er stor, med rundt én million observasjoner per datasett i perioden 2020–2026, kan det oppstå tidsavbrudd dersom hele perioden hentes ut i ett enkelt API-kall. For å redusere denne risikoen deles tidsperioden derfor opp i månedlige intervaller. En løkke henter deretter data for én måned om gangen. De månedlige datasettene settes sammen til én samlet tibble ved hjelp av `bind_rows()`, før det ferdige datasettet lagres for videre analyse. Ved å hente data én måned om gangen og lagre hovedtibbelen fortløpende, reduserer vi risikoen for å miste allerede innhentede data dersom et API-kall feiler. Dersom et API-kall feiler, fortsetter innhentingen med neste måned uten at tidligere innhentede data går tapt.

2.1.b NVE (JSON)[2]

Dataene fra NVE leveres i JSON-format (*JavaScript Object Notation*), et tekstbasert format der informasjonen er strukturert i nøstede objekter og arrayer. Dataene leses inn og parses slik at de kan bearbeides videre og organiseres i en tibble.

Dataene fra NVE er tilgjengelige på dags- eller ukesformat, noe som gjør det mulig å hente data for hele perioden 2020 - 2026 i ett API-kall. Ved innhenting av tilsig er det imidlertid rundt

[1] Se *Kilder/henting av data fra ENTSO-E* for den modulbaserte implementasjonen, der API-kallene er organisert i separate, gjenbrukbare filer.

[2] Se *Kilder/henting_av_data_NVE* for uthenting av tilsigsdata og magaisnfylling.

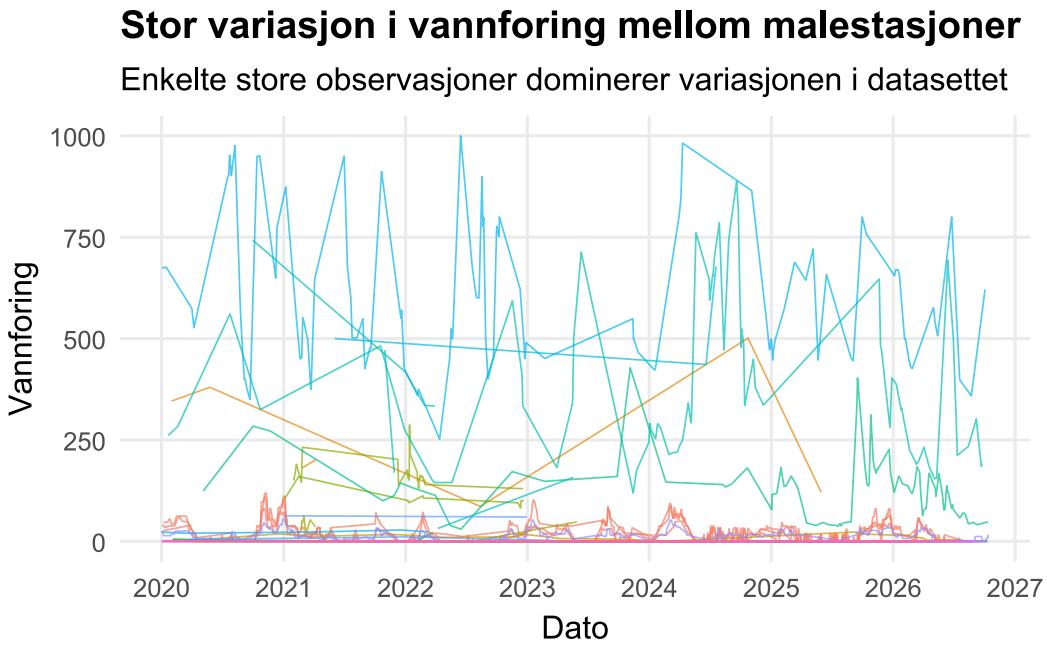
650 målestasjoner som skal behandles, noe som øker risikoen for at API-kallene overskrider tidsbegrensningen. For å redusere denne risikoen benyttes derfor samme fremgangsmåte som for ENTSO-E, der dataene hentes ut én målestasjon om gangen og lagres fortløpende underveis. Dataene fra de ulike målestasjonene samles deretter i én tibble ved hjelp av `bind_rows()`. Dette gjør innhentingen mer robust, ettersom en eventuell feil i et senere API-kall ikke fører til at tidligere innhentet data går tapt.

2.2 Bruk at dtplyr

Datasettene inneholder opptil 1,5 millioner datapunkter. For å effektivisere behandlingen av de store datamengdene benyttes dtplyr, som oversetter dplyr-operasjoner til mer effektive data.table-operasjoner. Dette bidrar til raskere databehandling og redusert minnebruk.

2.3 Utelating av forklaringsvariabler

Ettersom prosjektet har en utforskende tilnærming og undersøker et bredt utvalg av mulige forklaringsvariabler, ble også britisk strømpris, nedbør og tilsig vurdert inkludert i regresjonsmodellene. Britisk strømpris var imidlertid bare tilgjengelig for 2020. Inkludering av denne variabelen ville derfor ha redusert datagrunnlaget betydelig. For nedbør og tilsig var utfordringen først og fremst knyttet til datakvalitet og representativitet. Som vist i figur Figur 3 varierer målt vannføring betydelig mellom målestasjonene, samtidig som dataene inneholder mye støy. Det var dermed vanskelig å identifisere tydelige tidsmønstre og sammenhenger mellom tilsig og magasinfylling. For nedbør var det tilsvarende utfordrende å finne målinger som var representative for de enkelte prisområdene. På bakgrunn av disse vurderingene ble variablene utelatt fra de endelige regresjonsmodellene.



Figur 3: Støy i hydrologiske forhold

####Summary av vannføringsdataen Som vist i **?@fig-summary** har vannføringsdataene svært stor variasjon mellom målestasjonene. Vi har ikke tilstrekkelig grunnlag for å forklare de store forskjellene i målt tilsig eller avgjøre hvordan målingene best kan aggregeres til representative verdier. Det er derfor vanskelig å bruke dataene som pålitelige forklaringsvariabler, og tilsig utelates fra den endelige modellen.

```
      Min.    1st Qu.     Median       Mean    3rd Qu.       Max.       NA's
-1.000e+04  1.000e+00  3.000e+00  7.170e+16  1.700e+01  9.466e+22      39120
```

2.4 Databehandling og valg av forklaringsvariabler

3 Metode: Databehandling og regresjonsanalyse

3.1 Databehandling og valg av forklaringsvariabler[3]

For å gjennomføre analysen ønsker vi å sammenstille alle datakildene i én felles tibble. Siden dataene har ulik tidsoppløsning, må de først bearbeides slik at de kan kobles sammen på en konsistent måte. Strømpriser, forbruk og kraftproduksjon aggregeres til én observasjon per time og prisområde. Dette innebærer at dersom det finnes flere målinger innenfor samme time, beregnes gjennomsnittet. Tilsig og magasinfylling behandles separat og aggregeres til én observasjon per dag og prisområde. Deretter sammenstilles datasettene ved hjelp av left_join(), med norske strømpriser som utgangspunkt.

3.1.a Manglende observasjoner og klargjøring av data[4]

Før modellene estimeres, fjernes observasjoner med manglende eller ugyldige verdier separat for hvert prisområde. Dette er nødvendig fordi regresjonsmodellene krever gyldige verdier for både den avhengige variabelen og samtlige forklaringsvariabler. Som vist i Tabell 2, beholdes omtrent 99 % av observasjonene i samtlige prisområder etter filtreringen.

Deretter deles dataene kronologisk i et treningssett med 80 prosent av observasjonene og et testsett med de resterende 20 prosentene ved hjelp av initial_time_split(). Som vist i Tabell 2, utgjør treningssettet 80 prosent av observasjonene, mens testsettet utgjør de resterende 20 prosentene.

En kronologisk inndeling er egnet for tidsseriedata fordi modellene estimeres på historiske observasjoner og evalueres på senere observasjoner. Dette sikrer at fremtidige observasjoner ikke brukes til å predikere fortiden.

[3] Se *analyse/analyse_steg4/ferdig_til_tibble.R*

[4] Se *analyse/analyse_steg4/analysen_vi_skal_bruke.R*

Tabell 2: Antall observasjoner før og etter rensing per prisområde.

Prisomrade	Andel beholdt	Antall i testsettet	Antall i treningsettet
NO1	99.3%	11,575	46,298
NO2	99.0%	11,523	46,092
NO3	99.2%	11,536	46,144
NO4	99.3%	11,400	45,599
NO5	99.0%	11,488	45,952

3.2 Oppdeling av data og estimering av modellene

Forklaringsvariablene og den avhengige variabelen ble standardisert ved hjelp av gjennomsnitt og standardavvik beregnet fra treningssettet. De samme verdiene ble deretter brukt til å standardisere testsettet. Dette sikrer at informasjon fra testperioden ikke brukes ved beregningen av standardiseringsparametrene. Standardiseringen gjør dessuten regresjonskoeffisientene mer sammenlignbare, siden variablene uttrykkes i standardavvik i stedet for sine opprinnelige måleenheter.

Det ble estimert en lineær regresjonsmodell for hvert prisområde ved hjelp av minste kvadraters metode. Modellene ble deretter brukt til å predikere strømprisene i testperioden. Prediksjonene ble konvertert tilbake til den opprinnelige prisskalaen før evalueringen.

3.3 Evaluering av prediksjonene

Modellenes prediksjonsevne ble evaluert ved hjelp av tre mål: RMSE, MAE og (R^2).

- **RMSE (root mean squared error)** måler størrelsen på prediksjonsfeilene og gir større vekt til store feil. En lavere verdi indikerer bedre prediksjonsevne.
- **MAE (mean absolute error)** måler den gjennomsnittlige absolutte forskjellen mellom observert og predikert strømpris. En lavere verdi indikerer at prediksjonene i gjennomsnitt ligger nærmere de observerte prisene.
- **(R^2)** beregnet på testsettet viser hvor godt prediksjonene samsvarer med variasjonen i de observerte prisene, sammenlignet med et referansenivå basert på gjennomsnittet i testperioden. En høyere verdi indikerer bedre samsvar. Verdien kan også være negativ dersom modellen predikerer dårligere enn dette referansenivået.

Sett inn Tabell Y: RMSE, MAE og (R^2) for testsettet i hvert prisområde.

Tabellen gir grunnlag for å sammenligne prediksjonsevnen mellom prisområdene. Sammenligningen må imidlertid tolkes med forsiktighet, ettersom prisområdene kan ha ulik prisvolatilitet og forskjellige markedsforhold. Det er derfor nyttig å vurdere både RMSE og MAE sammen med (R^2), fremfor å basere vurderingen på ett enkelt mål.

3.4 Regresjonskoeffisienter og sammenhenger

For å undersøke hvilke forklaringsvariabler som har sterkest sammenheng med strømprisen, ble de standardiserte regresjonskoeffisientene hentet ut fra hver modell. Koeffisientene viser hvordan

den predikerte strømprisen endres, målt i standardavvik, når en forklaringsvariabel øker med ett standardavvik, mens de øvrige variablene holdes konstante.

Figur X viser de estimerte standardiserte regresjonskoeffisientene for de ulike prisområdene. Figuren inkluderer også tilnærmede 95 prosent konfidensintervaller. Koeffisienter over null indikerer en positiv betinget sammenheng, mens koeffisienter under null indikerer en negativ betinget sammenheng. Konfidensintervallene gir informasjon om usikkerheten i koeffisientestimatene.

Sett inn Figur X: Standardiserte regresjonskoeffisienter med tilnærmede 95 prosent konfidensintervaller.

Figuren kan brukes til å undersøke om sammenhengene varierer mellom prisområdene. Siden NO1 og NO2 inkluderer europeisk strømpris, mens NO3–NO5 ikke gjør det, må sammenligninger av koeffisientene ta hensyn til at modellspesifikasjonene er forskjellige. Koeffisientene viser statistiske sammenhenger gitt variablene i modellen, og kan ikke uten videre tolkes som kausale effekter.

3.5 Observert og predikert strømpris

For å vurdere hvordan modellene følger den faktiske prisutviklingen, ble predikerte strømpriser sammenlignet med observerte priser i testperioden. Figur Y viser denne sammenligningen for NO3, mens Figur Z viser resultatene for alle fem prisområdene.

Sett inn Figur Y: Observert og predikert strømpris i NO3.

Sett inn Figur Z: Observert og predikert strømpris for alle prisområdene.

Disse figurene gjør det mulig å undersøke om modellene fanger opp den overordnede prisutviklingen, og om de klarer å følge perioder med store prisendringer. Avstanden mellom de observerte og predikerte kurvene illustrerer prediksjonsfeilene. Det bør særlig undersøkes om modellene systematisk undervurderer eller overvurderer høye pristopper, ettersom en lineær modell kan ha begrenset evne til å fange opp brå og ekstreme prisbevegelser.

3.6 Oppsummering av fremgangsmåten

Analysen følger dermed en trinnvis prosess der data fra flere kilder først ble sammenstilt og kontrollert, før forklaringsvariablene ble valgt og separate regresjonsmodeller ble estimert for hvert prisområde. Manglende observasjoner ble håndtert før dataene ble delt kronologisk i trenings- og testsett. Modellene ble estimert på treningsdataene, og prediksjonsevnen ble vurdert på senere observasjoner ved hjelp av RMSE, MAE og (R^2). Til slutt ble de standardiserte regresjonskoeffisientene og forholdet mellom observerte og predikerte priser undersøkt grafisk.

Denne fremgangsmåten gir grunnlag for å vurdere både hvilke variabler som har statistiske sammenhenger med strømprisen, og hvor godt modellene predikerer priser i testperioden. Resultatene må tolkes i lys av modellspesifikasjonene, tilgjengeligheten av data og at viktige faktorer som kan påvirke strømprisen, ikke nødvendigvis er inkludert.

Bibliografi

[1] SSB, «Hva koster det å produsere vannkraft?». [Online]. Tilgjengelig på: https://www.ssb.no/energi-og-industri/energi/statistikk/elektrisitetspriser