Første utkast for kildebeskrivelse

kandidatnummer

16 oktober 2026

1 Datainnsamlingen

Datainnsamlignen har vært en stor del av prosjektet, da jeg har hentet data fra fire ulike API-er, levert i ulikt formater. Da dataen har høy tidsoppløsning (15 minutter til dagsoppløsning) er dette svært store datasett, som krever strukturert og effektiv kode å hente ut.

I mappen *Kilder* gjennomføres API-kallende, før de lagres som RDS-filer i *Datasett*. Når vi skal analysere datasettene henter vi RDS-filene ut fra *Datasett*, slik at vi unngår å gjøre det tid- og resusskrevende API-kallet flere ganger enn nødvendig.

I dette prosjeket har jeg brukt to kilder, ENSTO-E og NVE.

Kilde	Datasett	Format
ENTSO-E	Europeisk datasett for strømpriser (spotpriser i kraftmarkedet), kraftflyt og produksjon fordelt på produksjonstype.	XML
NVE	Norges vassdrags- og energidirektorat. Magasinstatistikk (fyllingsgrad) og tilsig.	JSON

1.1 ENTSTO-E

1.1.a Formatet til API-et (XML)

Dataene fra ENTSO-E leveres i XML-format, et tekstbasert format der informasjonen er organisert i en hierarkisk trestruktur. XML-responsen fra API-et leses inn og parses for å gjøre innholdet tilgjengelig for videre behandling. Ved hjelp av XML-parsing identifiseres relevante elementer og attributter som inneholder informasjon om blant annet tidspunkt, spotpriser (**A44**) , produksjon og forbruk(**A16**). For å hente data fra et bestemt prisområde benyttes en tilhørende EIC-kode (*Energy Identification Code*), som identifiserer området i kraftmarkedet. API-forespørselen spesifiserer dermed både hvilken EIC-kode og hvilken type data som skal hentes ut. Den samme overordnede kodestrukturen benyttes for all datainnsamling fra ENTSO-E, mens parameterne tilpasses etter hvilken informasjon som etterspørres. De relevante dataene hentes deretter ut av XML-strukturen, bearbeides og samles i en tibble for videre analyse.

«API-nøkkel» -> «EIC-kode» -> «Hente data» -> «Bearbeide XML» -> «Sette sammen tibble» -> «Lagre data»

1.1.b Behandling av store datasett

Ettersom datamengden er stor, med rundt én million observasjoner per datasett i perioden 2020–2026, kan det oppstå tidsavbrudd dersom hele perioden hentes ut i ett enkelt API-kall. For å redusere denne risikoen deles tidsperioden derfor opp i månedlige intervaller. En løkke henter deretter data for én måned om gangen. De månedlige datasettene settes sammen til én samlet tibble ved hjelp av `bind_rows()`, før det ferdige datasettet lagres for videre analyse. Ved å hente data én måned om gangen og lagre hovedtibbelen fortløpende, reduserer vi risikoen for å miste allerede innhentede data dersom et API-kall feiler. Dersom et API-kall feiler, fortsetter innhentingen med neste måned uten at tidligere innhentede data går tapt.

Som tidligere nevnt leveres dataene fra ENTSO-E i XML-format, der hvert prisområde identifiseres ved hjelp av en egen EIC-kode. Dataene hentes inn måned for måned og separat for hvert prisområde, før datasettene sammenstilles ved hjelp av `left_join()`. Resultatet er et datasett på *wide format*, der variablene for de ulike prisområdene er organisert i separate kolonner. For å gjøre dataene mer egnet for videre analyse, transformeres de deretter til *long format* og lagres som RDS-filer. Ettersom datamengden omfatter flere millioner datapunkter, benyttes `dtplyr` for å effektivisere behandlingen av dataene og redusere ressursbruken.

```
maaneder <- seq(
  from = as.Date(format(start_dato, "%Y-%m-01")),
  to = as.Date(format(slutt_dato, "%Y-%m-01")),
  by = "month")
```

1.2 NVE

1.2.a JSON-formatet

Dataene fra NVE leveres i JSON-format (*JavaScript Object Notation*), et tekstbasert format der informasjonen er strukturert i nøstede objekter og arrayer. Dataene leses inn og parses slik at de kan bearbeides videre og organiseres i en tibble.

Dataene fra NVE er tilgjengelige på dags- eller ukesformat, noe som gjør det mulig å hente data for hele perioden 2020 - 2026 i ett API-kall. Ved innhenting av tilsig er det imidlertid rundt 650 målestasjoner som skal behandles, noe som øker risikoen for at API-kallene overskrider tidsbegrensningen. For å redusere denne risikoen benyttes derfor samme fremgangsmåte som for ENTSO-E, der dataene hentes ut én målestasjon om gangen og lagres fortløpende underveis. Dataene fra de ulike målestasjonene samles deretter i én tibble ved hjelp av `bind_rows()`. Dette gjør innhentingen mer robust, ettersom en eventuell feil i et senere API-kall ikke fører til at tidligere innhentede data går tapt.

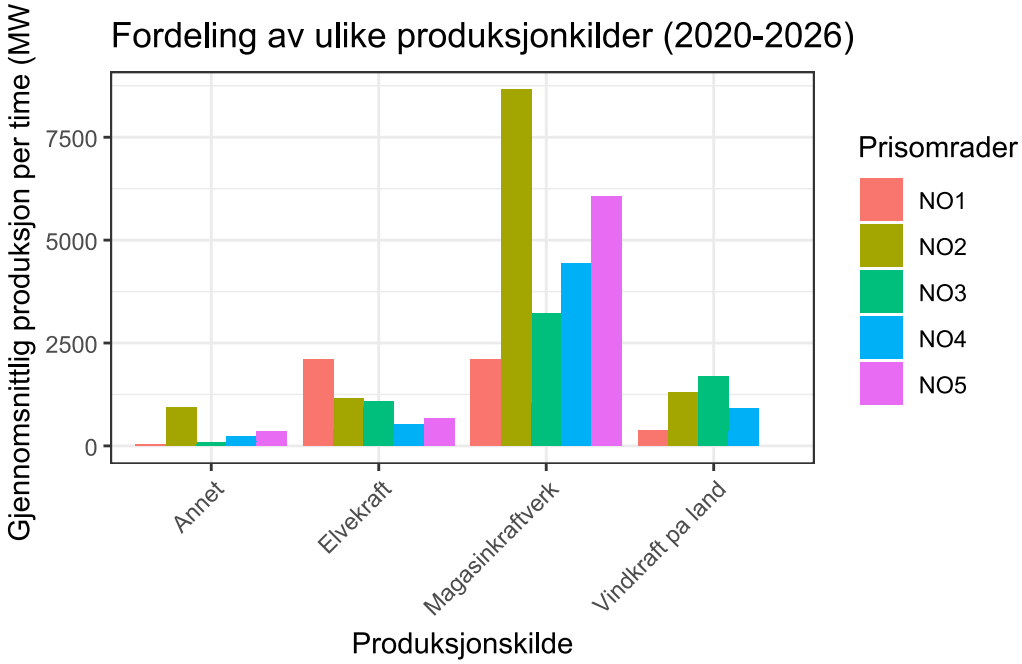
1.3 Behandling av dataene

Prosjektet benytter data fra flere kilder med ulik tidsoppløsning. Mens Norge og Tyskland har prisobservasjoner hvert 15. minutt, har Danmark og Nederland timesobservasjoner. For å sikre

et sammenlignbart datagrunnlag aggregerer vi derfor prisene til timesnivå. Dette gir et mer konsistent datagrunnlag for analysen, men innebærer at variasjoner i prisene innad i hver time går tapt.Da vi ønsker dataen på samme format, aggregerer vi også strømdataen for Norge til timesnivå. I scriptet "sette_sasammen_til_en_tibble*[1] tar vi hensyn til dette. alle datasettene settes sammen til

2 Overblikk over kraftproduksjon i Norge

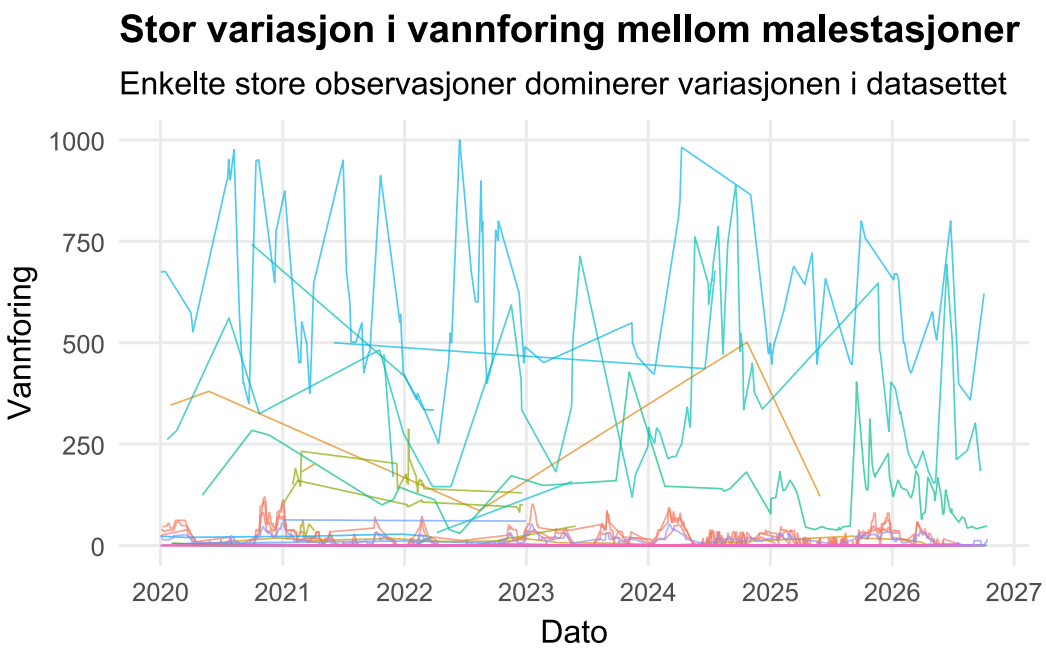
For å gi et overordnet bilde av den norske kraftproduksjonen viser figuren gjennomsnittlig produksjon per time (MW), fordelt på produksjonskilder og prisområder i perioden 2020–2026. Figuren viser at vannkraft med magasin utgjør en betydelig del av produksjonen i samtlige prisområder. Samtidig fremgår det geografiske forskjeller i produksjonsmiksen. NO1 har et relativt stort bidrag fra uregulert elvekraft, mens vindkraft på land står for en større andel av produksjonen i NO2 og NO3. Samlet sett illustrerer figuren at norsk kraftproduksjon i hovedsak er basert på vannkraft, hvorav en betydelig del kan reguleres gjennom magasinering.



3 Støy i hydrologiske forhold

Det ble forsøkt å predikere magasinfyllingen ved hjelp av nedbør, aggregert nedbør og tilsig. Analysene viste imidlertid betydelige utfordringer knyttet til støy og store forskjeller i størrelsesorden mellom observasjonene. Enkelte målestasjoner har svært høye vannføringsverdier, som dominerer variasjonen i datasettet og gjør det vanskelig å identifisere tydelige sammenhenger. Et sammendrag av tilsigdataene er vedlagt for å illustrere disse utfordringene. På bakgrunn av dette ble de hydrologiske variablene utelatt fra det videre arbeidet.

[1] sette_sammen_til_en_tibble



Summary av vannføringsdataen

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
-1.000e+04	1.000e+00	3.000e+00	7.170e+16	1.700e+01	9.466e+22	39120