Første utkast for kildebeskrivelse

kandidatnummer

14 oktober 2026

1 Datainnsamlingen

Datainnsamlignen har vært en stor del av prosjektet, da jeg har hentet data fra fire ulike API-er, levert i ulikt formater. Da dataen har høy tidsoppløsning (15 minutter til dagsoppløsning) er dette svært store datasett, som krever strukturert og effektiv kode å hente ut.

I mappen *Kilder* gjennomføres API-kallende, før de lagres som RDS-filer i *Datasett*. Når vi skal analysere datasettene henter vi RDS-filene ut fra *Datasett*, slik at vi unngår å gjøre det tid- og resusskrevende API-kallet flere ganger enn nødvendig.

I dette prosjeket har jeg brukt to kilder, ENSTO-E og NVE.

Kilde	Datasett	Format
ENTSO-E	Europeisk datasett for strømpriser (spotpriser i kraftmarkedet), kraftflyt og produksjon fordelt på produksjonstype.	XML
NVE	Norges vassdrags- og energidirektorat. Magasinstatistikk (fyllingsgrad) og tilsig.	JSON

1.1 ENTSTO-E

1.1.a Formatet til API-et (XML)

Dataene fra ENTSO-E leveres i XML-format, et tekstbasert format der informasjonen er organisert i en hierarkisk trestruktur. XML-responsen fra API-et leses inn og parses for å gjøre innholdet tilgjengelig for videre behandling. Ved hjelp av XML-parsing identifiseres relevante elementer og attributter som inneholder informasjon om blant annet tidspunkt, spotpriser (**A44**) , produksjon og forbruk(**A16**). For å hente data fra et bestemt prisområde benyttes en tilhørende EIC-kode (*Energy Identification Code*), som identifiserer området i kraftmarkedet. API-forespørselen spesifiserer dermed både hvilken EIC-kode og hvilken type data som skal hentes ut. Den samme overordnede kodestrukturen benyttes for all datainnsamling fra ENTSO-E, mens parameterne tilpasses etter hvilken informasjon som etterspørres. De relevante dataene hentes deretter ut av XML-strukturen, bearbeides og samles i en tibble for videre analyse.

«API-nøkkel» -> «EIC-kode» -> «Hente data» -> «Bearbeide XML» -> «Sette sammen tibble» -> «Lagre data»

1.1.b Behandling av store datasett

Ettersom datamengden er stor, med rundt én million observasjoner per datasett i perioden 2020–2026, kan det oppstå tidsavbrudd dersom hele perioden hentes ut i ett enkelt API-kall. For å redusere denne risikoen deles tidsperioden derfor opp i månedlige intervaller. En løkke henter deretter data for én måned om gangen. De månedlige datasettene settes sammen til én samlet tibble ved hjelp av `bind_rows()`, før det ferdige datasettet lagres for videre analyse. Ved å hente data én måned om gangen og lagre hovedtibbelen fortløpende, reduserer vi risikoen for å miste allerede innhentede data dersom et API-kall feiler. Dersom et API-kall feiler, fortsetter innhentingen med neste måned uten at tidligere innhentede data går tapt.

```
maaneder <- seq(
  from = as.Date(format(start_dato, "%Y-%m-01")),
  to = as.Date(format(slutt_dato, "%Y-%m-01")),
  by = "month")
```

1.2 NVE

1.2.a JSON-formatet

Dataene fra NVE leveres i JSON-format (*JavaScript Object Notation*), et tekstbasert format der informasjonen er strukturert i nøstede objekter og arrayer. Dataene leses inn og parses slik at de kan bearbeides videre og organiseres i en tibble.

Dataene fra NVE er tilgjengelige på dags- eller ukesformat, noe som gjør det mulig å hente data for hele perioden 2020 - 2026 i ett API-kall. Ved innhenting av tilsig er det imidlertid rundt 650 målestasjoner som skal behandles, noe som øker risikoen for at API-kallene overskrider tidsbegrensningen. For å redusere denne risikoen benyttes derfor samme fremgangsmåte som for ENTSO-E, der dataene hentes ut én målestasjon om gangen og lagres fortløpende underveis. Dataene fra de ulike målestasjonene samles deretter i én tibble ved hjelp av `bind_rows()`. Dette gjør innhentingen mer robust, ettersom en eventuell feil i et senere API-kall ikke fører til at tidligere innhentede data går tapt.