Første utkast for kildebeskrivelse

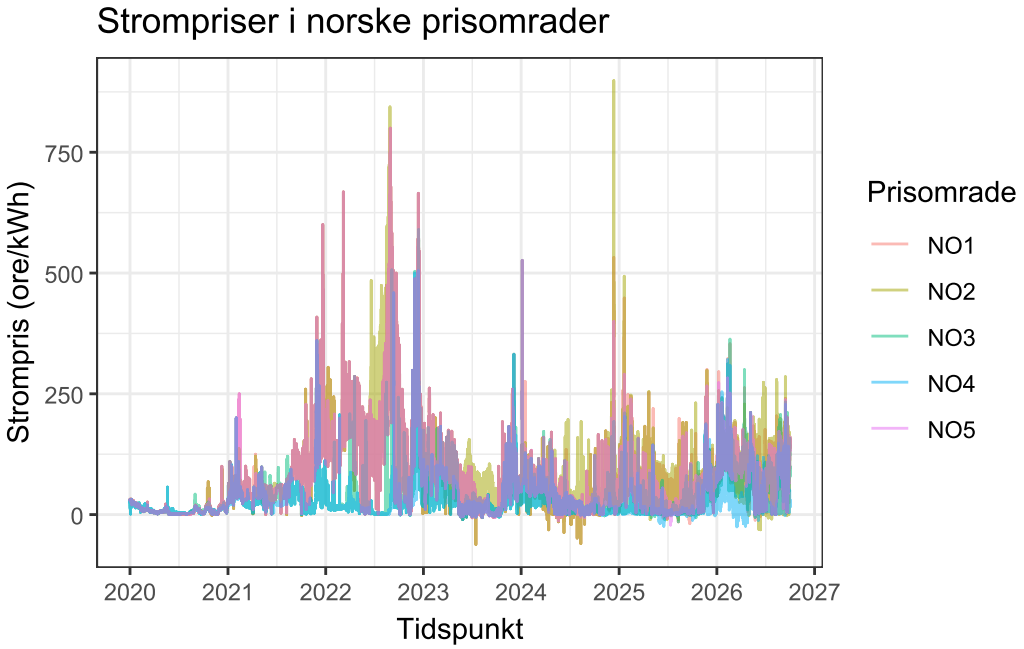
kandidatnummer

17 oktober 2026

1 Motivasjon

2 Motivasjon

Strømprissjokket i 2021–2022 aktualiserte spørsmålet om hva som driver strømprisene i Norge, og hvorfor prisutviklingen varierer mellom prisområdene. Som vist i Figur 1 er det betydelige forskjeller i både prisnivå og prisvariasjon mellom områdene. Dette gjør det relevant å undersøke om prisene i det europeiske kraftmarkedet kan bidra til å forklare utviklingen i Norge, og hvilken betydning prisområdenes tilknytning til det europeiske kontinentet har.



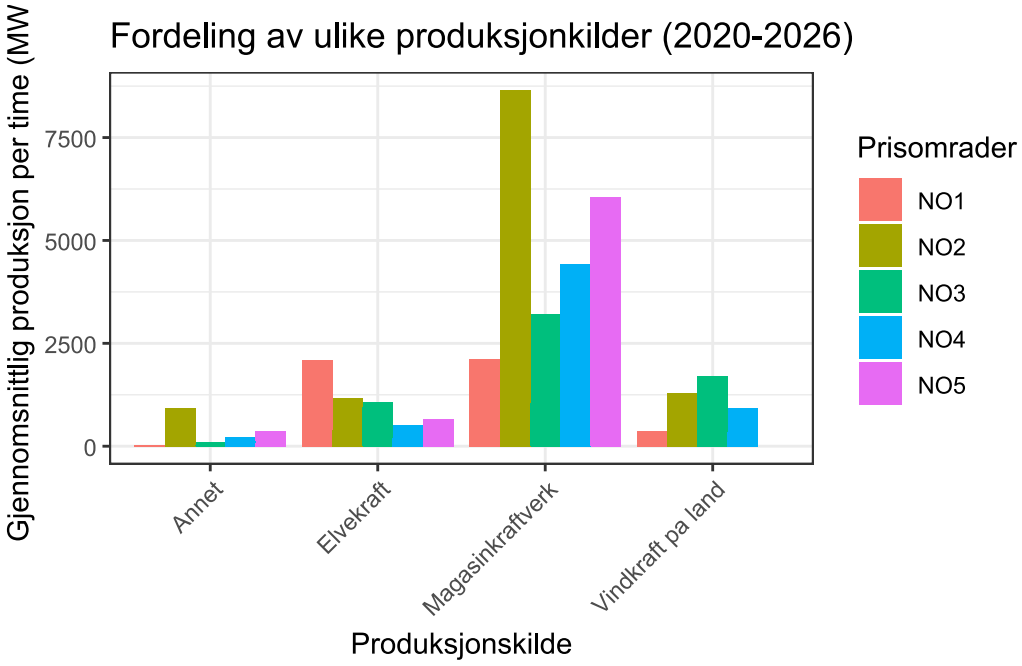
Figur 1: Utvikling i strømpriser i norske prisområder fra 2020 til 2026.

Samtidig varierer kraftproduksjonen mellom prisområdene, både når det gjelder produksjonskilder og muligheten til å regulere produksjonen. Som vist i Figur 2 utgjør vannkraft en betydelig del av kraftproduksjonen i alle prisområdene. Vannkraft med magasiner skiller seg fra mange andre

fornybare energikilder ved at produksjonen kan reguleres ved å styre hvor mye vann som slippes gjennom turbinene.

Dette gjør det relevant å undersøke om magasinfylling og hydrologiske forhold, som nedbør og tilsig, henger sammen med variasjoner i kraftproduksjon og strømpriser. I tillegg undersøkes strømforbruket, ettersom etterspørselen etter kraft også kan påvirke prisdannelsen.

Prosjektet har en utforskende datavitenskapelig tilnærming, der jeg undersøker mulige sammenhenger gjennom innsamling, bearbeiding og statistisk analyse av data. Flere hypoteser knyttet til kraftproduksjon, strømpriser, forbruk og hydrologiske forhold er undersøkt. Underveis i arbeidet utelates imidlertid enkelte forklaringsvariabler for strømprisen, grunnet støy, dårlig datakvalitet og utfordringer med å sammenstille data fra andre kilder.



Figur 2: Sammensetning av kraftprosuksjonen i ulike prisområder

3 Datainnsamlingen

Figur 1

Datainnsamlignen har vært en stor del av prosjektet, da jeg har hentet data fra fire ulike API-er, levert i ulikt formater. Da dataen har høy tidsoppløsning (15 minutter til dagsoppløsning) er dette svært store datasett, som krever strukturert og effektiv kode å hente ut.

I mappen *Kilder* gjennomføres API-kallende, før de lagres som RDS-filer i *Datasett*. Når vi skal analysere datasettene henter vi RDS-filene ut fra *Datasett*, slik at vi unngår å gjøre det tid- og resusskrevende API-kallet flere ganger enn nødvendig.

I dette prosjeket har jeg brukt to kilder, ENSTO-E og NVE.

Kilde	Datasett	Format
ENTSO-E	Europeisk datasett for strømpriser (spotpriser i kraftmarkedet), kraftflyt og produksjon fordelt på produksjonstype.	XML
NVE	Norges vassdrags- og energidirektorat. Magasinstatistikk (fyllingsgrad) og tilsig.	JSON

3.1 ENTSTO-E

3.1.a Formatet til API-et (XML)

Dataene fra ENTSO-E leveres i XML-format, et tekstbasert format der informasjonen er organisert i en hierarkisk trestruktur. XML-responsen fra API-et leses inn og parses for å gjøre innholdet tilgjengelig for videre behandling. Ved hjelp av XML-parsing identifiseres relevante elementer og attributter som inneholder informasjon om blant annet tidspunkt, spotpriser (**A44**) , produksjon og forbruk(**A16**). For å hente data fra et bestemt prisområde benyttes en tilhørende EIC-kode (*Energy Identification Code*), som identifiserer området i kraftmarkedet. API-forespørselen spesifiserer dermed både hvilken EIC-kode og hvilken type data som skal hentes ut. Den samme overordnede kodestrukturen benyttes for all datainnsamling fra ENTSO-E, mens parameterne tilpasses etter hvilken informasjon som etterspørres. De relevante dataene hentes deretter ut av XML-strukturen, bearbeides og samles i en tibble for videre analyse.

«API-nøkkel» -> «EIC-kode» -> «Hente data» -> «Bearbeide XML» -> «Sette sammen tibble» -> «Lagre data»

3.1.b Behandling av store datasett

Ettersom datamengden er stor, med rundt én million observasjoner per datasett i perioden 2020–2026, kan det oppstå tidsavbrudd dersom hele perioden hentes ut i ett enkelt API-kall. For å redusere denne risikoen deles tidsperioden derfor opp i månedlige intervaller. En løkke henter deretter data for én måned om gangen. De månedlige datasettene settes sammen til én samlet tibble ved hjelp av `bind_rows()`, før det ferdige datasettet lagres for videre analyse. Ved å hente data én måned om gangen og lagre hovedtibbelen fortløpende, reduserer vi risikoen for å miste allerede innhentede data dersom et API-kall feiler. Dersom et API-kall feiler, fortsetter innhentingen med neste måned uten at tidligere innhentede data går tapt.

Som tidligere nevnt leveres dataene fra ENTSO-E i XML-format, der hvert prisområde identifiseres ved hjelp av en egen EIC-kode. Dataene hentes inn måned for måned og separat for hvert prisområde, før datasettene sammenstilles ved hjelp av `left_join()`. Resultatet er et datasett på *wide format*, der variablene for de ulike prisområdene er organisert i separate kolonner. For å gjøre dataene mer egnet for videre analyse, transformeres de deretter til *long format* og lagres som RDS-filer. Ettersom datamengden omfatter flere millioner datapunkter, benyttes `dtplyr` for å effektivisere behandlingen av dataene og redusere ressursbruken.

```
maaneder <- seq(
  from = as.Date(format(start_dato, "%Y-%m-01")),
  to = as.Date(format(slutt_dato, "%Y-%m-01")),
  by = "month")
```

3.2 NVE

3.2.a JSON-formatet

Dataene fra NVE leveres i JSON-format (*JavaScript Object Notation*), et tekstbasert format der informasjonen er strukturert i nøstede objekter og arrayer. Dataene leses inn og parses slik at de kan bearbeides videre og organiseres i en tibble.

Dataene fra NVE er tilgjengelige på dags- eller ukesformat, noe som gjør det mulig å hente data for hele perioden 2020 - 2026 i ett API-kall. Ved innhenting av tilsig er det imidlertid rundt 650 målestasjoner som skal behandles, noe som øker risikoen for at API-kallene overskrider tidsbegrensningen. For å redusere denne risikoen benyttes derfor samme fremgangsmåte som for ENTSO-E, der dataene hentes ut én målestasjon om gangen og lagres fortløpende underveis. Dataene fra de ulike målestasjonene samles deretter i én tibble ved hjelp av `bind_rows()`. Dette gjør innhentingen mer robust, ettersom en eventuell feil i et senere API-kall ikke fører til at tidligere innhentede data går tapt.

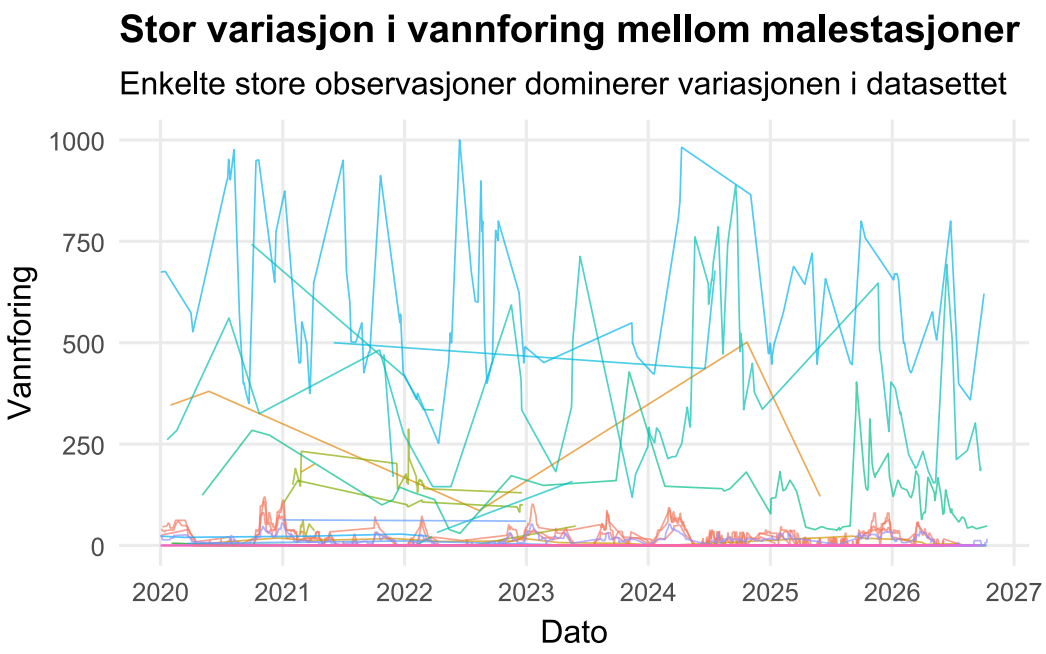
3.3 Behandling av dataene

Prosjektet benytter data fra flere kilder med ulik tidsoppløsning. Mens Norge og Tyskland har prisobservasjoner hvert 15. minutt, har Danmark og Nederland timesobservasjoner. For å sikre et sammenlignbart datagrunnlag aggregerer vi derfor prisene til timesnivå. Dette gir et mer konsistent datagrunnlag for analysen, men innebærer at variasjoner i prisene innad i hver time går tapt.Da vi ønsker dataen på samme format, aggregerer vi også strømdataen for Norge til timesnivå. I scriptet "sette_sasammen_til_en_tibble*[1] tar vi hensyn til dette. alle datasettene settes sammen til

4 Støy i hydrologiske forhold

Det ble forsøkt å predikere magasinfyllingen ved hjelp av nedbør, aggregert nedbør og tilsig fra ulike målestasjoner. Tilsigsdataene viste store forskjeller i målt vannføring mellom stasjonene. Enkelte stasjoner hadde betydelig høyere verdier enn andre og dominerte dermed variasjonen i datasettet. Samtidig var det vanskelig å følge utviklingen i vannføringen over tid og identifisere tydelige sammenhenger mellom tilsig og magasinfylling. Dette gjorde det utfordrende å aggregere målingene til representative verdier for de ulike prisområdene og bruke dem som forklaringsvariabler i prediksjonsmodellen. Et sammendrag av tilsigdataene er vedlagt for å illustrere variasjonen mellom målestasjonene. På bakgrunn av disse utfordringene ble de hydrologiske variablene utelatt fra de videre analysene.

[1] sette_sammen_til_en_tibble



Summary av vannføringsdataen

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
-1.000e+04	1.000e+00	3.000e+00	7.170e+16	1.700e+01	9.466e+22	39120