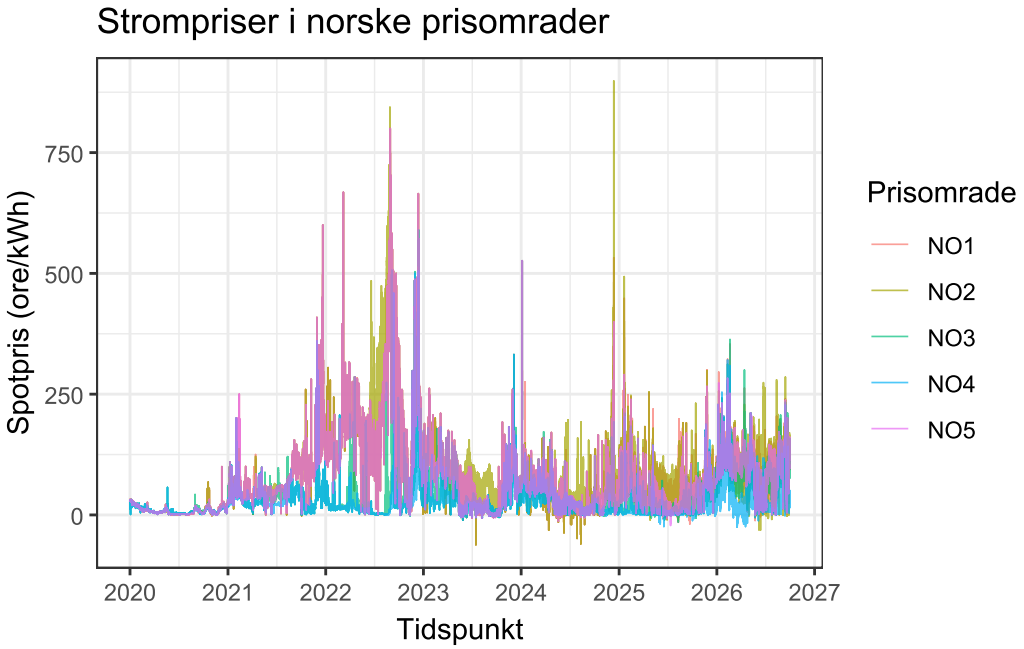
Første utkast for kildebeskrivelse

kandidatnummer

21 oktober 2026

1 Motivasjon

Norge har historisk hatt svært lave strømpriser, og frem til 2020 lå spotprisen mellom 20 - 45 øre/kWh (ekslusive nettleie og avgifter).[1] Dette har ført til at mye kraftkrevende industri er etablert i Norge (aluminumumskraftverk), og husholdninger har vært vant til relativt lave strømregninger, til tross for kalde vintre i dårlig isolerte hjem.



Figur 1: Utvikling i strømpriser i norske prisområder fra 2020 til 2026.

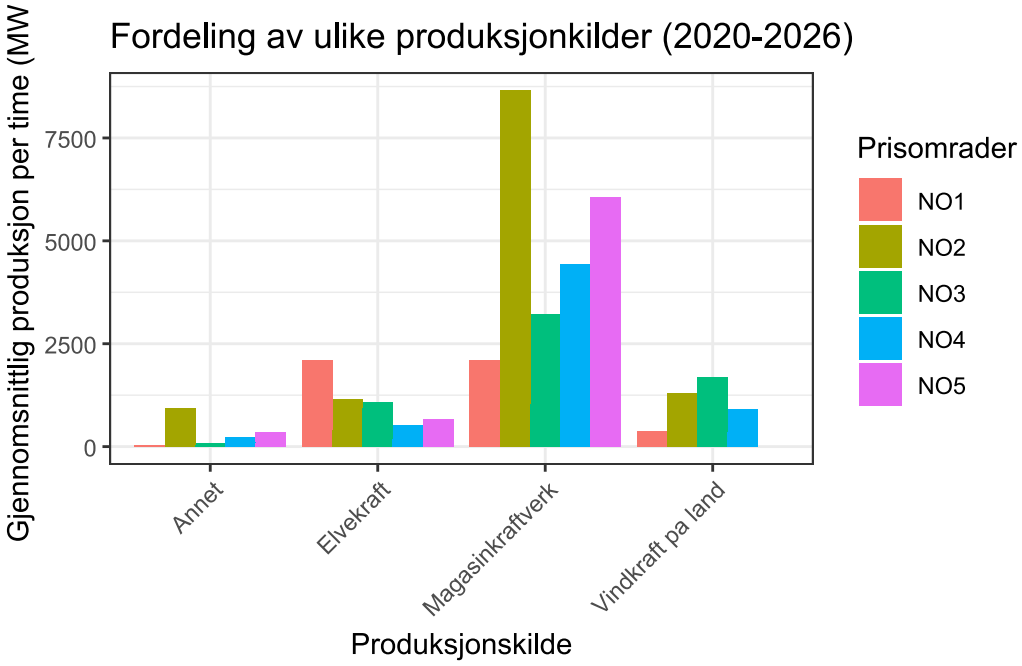
Strømprissjokket i 2021–2022 satte derfor strømprisene på den politiske dagsordenen, ettersom de kraftige prisøkningene rammet både husholdninger og bedrifter hardt. Figur 1 viser utviklingen i spotprisene i de fem norske prisområdene fra 2020 til 2026. Figuren viser en betydelig prisøkning i alle prisområdene, men med tydelige geografiske forskjeller. Prisøkningen var særlig kraftig i NO1, NO2 og NO5, mens prisene i NO3 og NO4 gjennomgående var lavere og mer stabile. Disse forskjellene reiser spørsmål om hvilke faktorer som kan forklare variasjonen i strømprisene

mellom prisområdene og over tid. Tabell 1 gir en rask oversikt over de ulike prisområdene, og hva som kjennetegner dem.

Tabell 1

Prisomrade	Geografisk omrade	Sentrale kjennetegn
NO1	Ostlandet	Hoyt forbruk og stor befolkning.
NO2	Sorvestlandet	Mye vannkraft og flere utenlandsforbindelser.
NO3	Midt-Norge	Mye vannkraft og begrenset overforingskapasitet sorover.
NO4	Nord-Norge	Mye vannkraft og relativt lavt forbruk.
NO5	Vestlandet	Mye vannkraft og varierende produksjon.

I tilegg til spotprisen, varierer også kraftproduksjonen mellom prisområdene, både når det gjelder produksjonskilder og muligheten til å regulere produksjonen. Som vist i Figur 2 utgjør vannkraft en betydelig del av kraftproduksjonen i alle prisområdene. Vannkraft med magasiner skiller seg fra mange andre fornybare energikilder ved at produksjonen kan reguleres ved å styre hvor mye vann som slippes gjennom turbinene.



Figur 2: Sammensetning av kraftprosuksjonen i ulike prisområder

Prosjektet har en utforskende datavitenskapelig tilnærming. Innledningsvis kartlegges et bredt utvalg av mulige forklaringsvariabler for strømprisen, blant annet kraftproduksjon, strømforbruk, magasinfylling, tilsig og nedbør. Dataene bearbeides og analyseres utforskende for å undersøke datakvalitet, tidsmessig dekning og mulige sammenhenger mellom variablene. Formålet er å kartlegge hvilke data som er egnet for videre analyse, og å etablere et grunnlag for statistisk modellering, der jeg skal bruke regresjon for å trene en modell for å predikere strømprisen.

2 Datainnsamlingen

Datainnsamlignen har vært en stor del av prosjektet, da jeg har innhentet data fra fire ulike API-er, levert i ulikt formater. Da dataen har høy tidsoppløsning (15 minutter til dagsoppløsning) er dette svært store datasett, som krever strukturert og effektiv kode å hente ut.

I mappen *Kilder* gjennomføres API-kallene og dataen bearbeides til rds-filer, før de lagres i *Datasett*. Når jeg senere utfører analyser på datasettene, hentes de ut som RDS-filer, slik at de tid- og resusskrevende API-kallene ikke gjennomføres flere ganger enn nødvendig. Prosjektet bruker to kilder for data, ENTSO-E og NVE, som leverer API-ene i to ulike formater.

2.1 Beskrivelse av kildene

Kilde	Forklaring av kilden	Format
ENTSO-E	Europeisk datasett for strømpriser (spotpriser i kraftmarkedet), kraftflyt og produksjon fordelt på produksjonstype.	XML
NVE	Norges vassdrags- og energidirektorat. Magasinstatistikk (fyllingsgrad) og tilsig.	JSON

2.1.a ENSTSO-E (XML)[1]

Dataene fra ENTSO-E leveres i XML-format, et tekstbasert format der informasjonen er organisert i en hierarkisk trestruktur. XML-responsen fra API-et leses inn og parses for å gjøre innholdet tilgjengelig for videre behandling. Ved hjelp av XML-parsing identifiseres relevante elementer og attributter som inneholder informasjon om blant annet tidspunkt, spotpriser (A44), produksjon og forbruk (A16).

For å hente data fra et bestemt prisområde benyttes en tilhørende EIC-kode (*Energy Identification Code*), som identifiserer området i kraftmarkedet. API-forespørselen spesifiserer dermed både hvilken EIC-kode og hvilken type data som skal hentes ut.

Datainnsamlingen er organisert modulbasert, der ulike deler av prosessen er fordelt på separate filer. Dette gjør koden mer oversiktlig og avgrenser kompleksiteten ved å samle funksjonalitet for ulike datakilder og datatyper i egne moduler. Siden dataene fra ENTSO-E leveres i en hierarkisk XML-struktur og behandles som nestede lister, kan den samme overordnede kodestrukturen gjenbrukes for flere datatyper, blant annet spotpriser og kraftproduksjon. Selv om innholdet og enkelte elementer varierer, følger innlesing, parsing og uttrekk av data de samme grunnleggende prinsippene.

De relevante dataene hentes deretter ut av XML-strukturen, bearbeides og samles i en tibble, før de som nevnt lagres som RDS-filer i *Datasett*.

Ettersom datamengden er stor, med rundt én million observasjoner per datasett i perioden 2020–2026, kan det oppstå tidsavbrudd dersom hele perioden hentes ut i ett enkelt API-kall. For å

[1] Se *Kilder/henting av data fra ENTSO-E* for den modulbaserte implementasjonen, der API-kallene er organisert i separate, gjenbrukbare filer.

redusere denne risikoen deles tidsperioden derfor opp i månedlige intervaller. En løkke henter deretter data for én måned om gangen. De månedlige datasettene settes sammen til én samlet tibble ved hjelp av `bind_rows()`, før det ferdige datasettet lagres for videre analyse. Ved å hente data én måned om gangen og lagre hovedtibbelen fortløpende, reduserer vi risikoen for å miste allerede innhentede data dersom et API-kall feiler. Dersom et API-kall feiler, fortsetter innhentingen med neste måned uten at tidligere innhentede data går tapt.

2.1.b NVE (JSON)[2]

Dataene fra NVE leveres i JSON-format (*JavaScript Object Notation*), et tekstbasert format der informasjonen er strukturert i nøstede objekter og arrayer. Dataene leses inn og parses slik at de kan bearbeides videre og organiseres i en tibble.

Dataene fra NVE er tilgjengelige på dags- eller ukesformat, noe som gjør det mulig å hente data for hele perioden 2020 - 2026 i ett API-kall. Ved innhenting av tilsig er det imidlertid rundt 650 målestasjoner som skal behandles, noe som øker risikoen for at API-kallene overskrider tidsbegrensningen. For å redusere denne risikoen benyttes derfor samme fremgangsmåte som for ENTSO-E, der dataene hentes ut én målestasjon om gangen og lagres fortløpende underveis. Dataene fra de ulike målestasjonene samles deretter i én tibble ved hjelp av `bind_rows()`. Dette gjør innhentingen mer robust, ettersom en eventuell feil i et senere API-kall ikke fører til at tidligere innhentet data går tapt.

2.2 Bruk at dtplyr

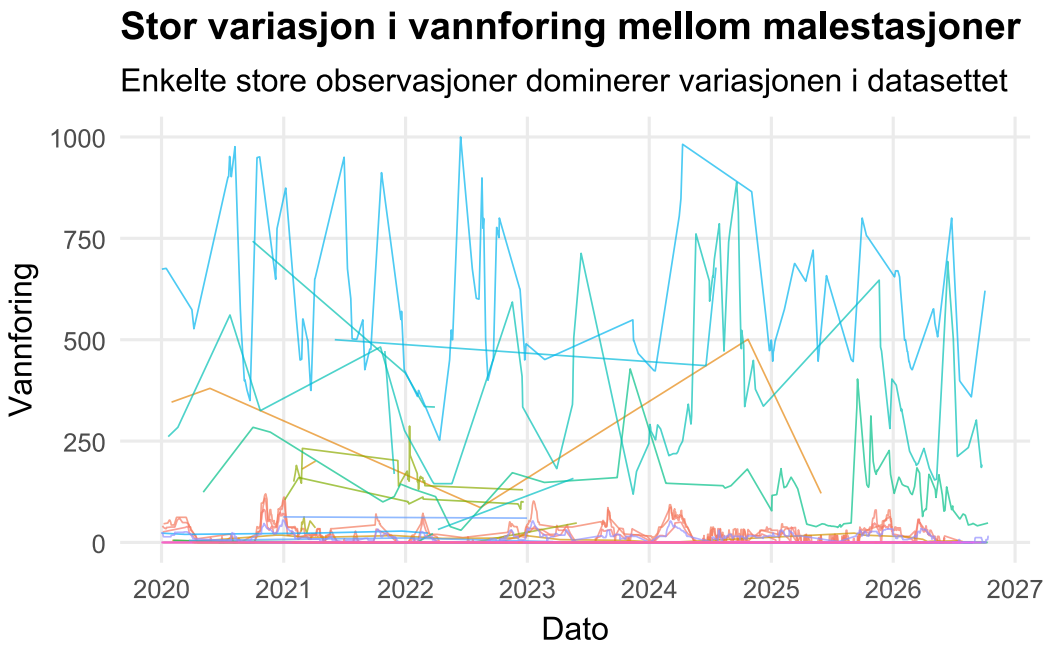
Datasettene inneholder opptil 1,5 millioner datapunkter. For å effektivisere behandlingen av de store datamengdene benyttes dtplyr, som oversetter dplyr-operasjoner til mer effektive data.table-operasjoner. Dette bidrar til raskere databehandling og redusert minnebruk.

2.3 Utelating av forklaringsvariabler

Ettersom prosjektet har en utforskende tilnærming og undersøker et bredt utvalg av mulige forklaringsvariabler, ble også britisk strømpris, nedbør og tilsig vurdert inkludert i regresjonsmodellene. Britisk strømpris var imidlertid bare tilgjengelig for 2020. Inkludering av denne variabelen ville derfor ha redusert datagrunnlaget betydelig for NO3 (prissonen som har utenlandskabler til Storbritannia).

Ettersom magasinkraftverk er avhengige av nedbør og tilsig for å opprettholde magasinfyllingen, ble det forsøkt å inkludere data om hydrologiske forhold i analysen. Det viste seg imidlertid å være utfordrende å finne målestasjoner som var representative for de aktuelle vannmagasinene. I tillegg var det betydelig variasjon i målt vannføring mellom målestasjonene, og måledataene inneholdt mye støy. Dette skapte usikkerhet knyttet til både datakvaliteten og dataenes representativitet. Som vist i figur Figur 3 varierer målt vannføring betydelig mellom målestasjonene. På bakgrunn av disse utfordringene ble det vurdert som lite hensiktsmessig å inkludere de hydrologiske variablene i den videre analysen.

[2] Se *Kilder/henting_av_data_NVE* for uthenting av tilsigsdata og magaisnfylling.



Figur 3: Støy i hydrologiske forhold

####Summary av vannføringsdataen Som vist i **?@fig-summary** har vannføringsdataene svært stor variasjon mellom målestasjonene. Vi har ikke tilstrekkelig grunnlag for å forklare de store forskjellene i målt tilsig eller avgjøre hvordan målingene best kan aggregeres til representative verdier. Det er derfor vanskelig å bruke dataene som pålitelige forklaringsvariabler, og tilsig utelates fra den endelige modellen.

```
      Min.    1st Qu.     Median       Mean    3rd Qu.       Max.       NA's
-1.000e+04  1.000e+00  3.000e+00  7.170e+16  1.700e+01  9.466e+22      39120
```

2.4 Databehandling og valg av forklaringsvariabler

3 Metode: Databehandling og regresjonsanalyse

3.0.a Valg av modell

Det finnes flere maskinlæringsmetoder for å modellere kontinuerlige variabler, blant annet Random Forest, XGBoost, OLS og LASSO. Trebaserte metoder som Random Forest og XGBoost kan fange opp komplekse og ikke-lineære sammenhenger, mens lineære regresjonsmodeller som OLS gir koeffisienter som er enklere å tolke.

Formålet med prosjektet er å undersøke overordnede sammenhenger mellom strømpriser og mulige forklaringsvariabler, snarere enn å maksimere modellens prediksjonsnøyaktighet. Derfor velger vi å sette opp en linjær regresjonsmodell, som gjør det mulig å undersøke sammenhengen mellom hver forklaringsvariabel og strømprisen, gitt at de øvrige variablene i modellen holdes

konstante. Den relativt enkle modellstrukturen gjør resultatene lettere å tolke, men begrenser samtidig modellens evne til å fange opp ikke-lineære sammenhenger og ekstreme prisbevegelser.

Vi kontruerer dermed en linjær regresjonsmodell med normalfordelte feilledd på formen

For hvert prisområde j og tidspunkt t estimeres følgende lineære regresjonsmodell:

$$P_{t,j} = \beta_{0,j} + \beta_{1,j}F_{t,j} + \beta_{2,j}M_{t,j} + \beta_{3,j}V_{t,j} + \varepsilon_{t,j},$$

for prisområdene NO3, NO4 og NO5. For NO1 og NO2 inkluderes også europeisk strømpris som forklaringsvariabel:

$$P_{t,j} = \beta_{0,j} + \beta_{1,j}F_{t,j} + \beta_{2,j}M_{t,j} + \beta_{3,j}V_{t,j} + \beta_{4,j}E_t + \varepsilon_{t,j}.$$

Her betegner $P_{t,j}$ strømprisen i prisområde j på tidspunkt t, $F_{t,j}$ strømforbruket, $M_{t,j}$ produksjonen fra magasinkraftverk, $V_{t,j}$ øvrige produksjonsvariabler og E_t europeisk strømpris. Konstantleddet betegnes med $\beta_{0,j}$, mens $\hat{\beta}_{1,j}..., \hat{\beta}_{4,j}$ er regresjonskoeffisientene. Det normalfordelte feilleddet betegnes med $\varepsilon_{t,j}$.

3.1 Databehandling og valg av forklaringsvariabler[3]

For å gjennomføre analysen ønsker vi å sammenstille alle datakildene i én felles tibble. Siden dataene har ulik tidsoppløsning, må de først bearbeides slik at de kan kobles sammen på en konsistent måte. Strømpriser, forbruk og kraftproduksjon aggregeres til én observasjon per time og prisområde. Dette innebærer at dersom det finnes flere målinger innenfor samme time, beregnes gjennomsnittet. Tilsig og magasinfylling behandles separat og aggregeres til én observasjon per dag og prisområde. Deretter sammenstilles datasettene ved hjelp av left_join(), med norske strømpriser som utgangspunkt.

3.1.a Manglende observasjoner og klargjøring av data[4]

Før vi trener modellen på datasettet, fjernes observasjoner med manglende eller ugyldige verdier separat for hvert prisområde. Dette er nødvendig fordi regresjonsmodellene krever gyldige verdier for både den avhengige variabelen og samtlige forklaringsvariabler. Som vist i Tabell 2, beholdes omtrent 99 % av observasjonene i samtlige prisområder etter filtreringen.

Tabell 2: Antall observasjoner før og etter rensing per prisområde.

Prisomrade	Andel beholdt	Antall i testsettet	Antall i treningsettet
NO1	99.3%	11,575	46,298
NO2	99.0%	11,523	46,092
NO3	99.2%	11,536	46,144
NO4	99.3%	11,400	45,599
NO5	99.0%	11,488	45,952

[3]Se *analyse/analyse_steg4/ferdig_til_tibble.R*

[4]Se *analyse/analyse_steg4/analysen_vi_skal_bruke.R* for hele scriptet.

Dataene deles kronologisk ved hjelp av `initial_time_split()`, der de første 80 prosentene av observasjonene utgjør treningssettet, mens de resterende 20 prosentene utgjør testsettet, som vist i Tabell 2.

For tidsseriedata er en kronologisk splitting hensiktsmessig, da modellene estimeres på historiske observasjoner og evalueres på senere data. Dermed unngår man at fremtidige observasjoner brukes til å predikere fortidige verdier. Ettersom modellene for de ulike prissonene estimeres separat, varierer delingsdatoen noe, som følge av ulik datadekning og filtrering av observasjoner. For å angi et felles tidspunkt for skillet mellom trenings- og testsettet, beregnes derfor gjennomsnittet av delingsdatoene. Dette tilsvarer omtrent tidspunktet der 80 prosent av observasjonene er passert.

```
[1] "Splitten skjer 2025-05-17"
```

Da forklaringsvariablene har ulik størrelsesorden, standardiseres de for å gjøre dem lettere å sammenligne. Dette gjøres ved hjelp av funksjonen standardiser(), som sentrerer hver variabel rundt gjennomsnittet og skalerer den med standardavviket. Variablene får dermed gjennomsnitt lik null og standardavvik lik én, slik at de uttrykkes på samme skala uavhengig av opprinnelig måleenhet.

```
  standardiser <- function(data) {
    data |>
      mutate(
        across(all_of(variabler),~
                  (.x - gjennomsnitt[[cur_column()]])/
standardavvik[[cur_column()]]
                ))}
```

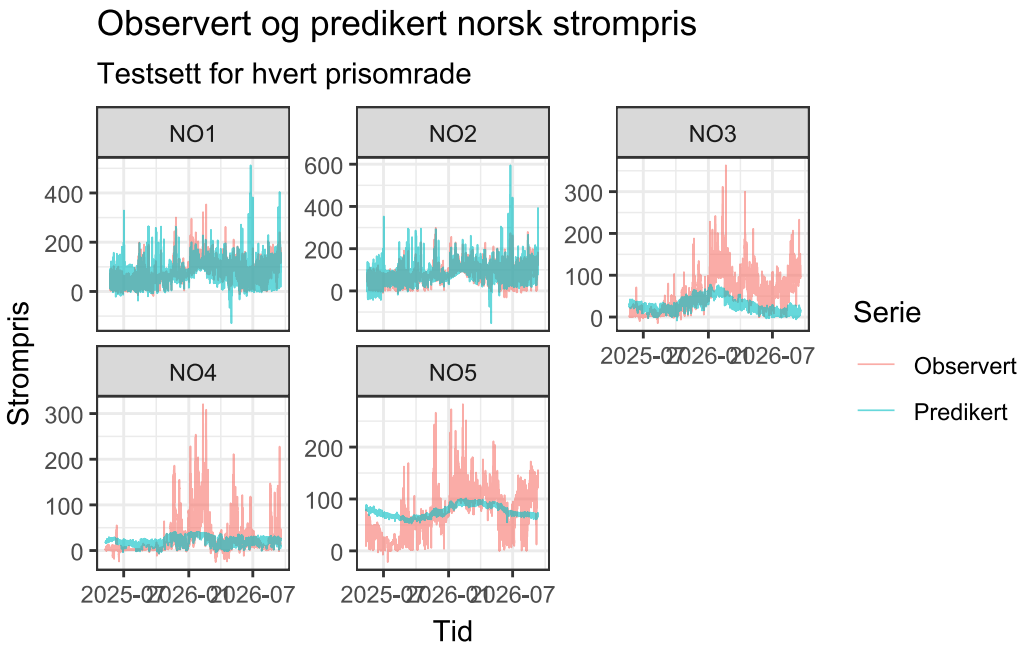
Modelleringen gjennomføres i tidymodels, der en workflow kombinerer regresjonsmodellen med en formel som spesifiserer hvilke forklaringsvariabler som inngår. Det estimeres separate lineære regresjonsmodeller med minste kvadraters metode (OLS) for hvert av de fem norske prisområdene. Modellene tilpasses i en løkke, der det tas hensyn til at NO1 og NO2 inkluderer europeisk strømpris som forklaringsvariabel, mens denne variabelen utelates for NO3, NO4 og NO5.

De tilpassede modellene brukes til å predikere strømprisene i testsettet. Prediksjonene transformeres deretter fra standardisert format tilbake til den opprinnelige prisskalaen, slik at de kan sammenlignes med de observerte strømprisene. Modellens prediksjonsevne evalueres ved hjelp av MSE og R^2, basert på prisobservasjonene i testperioden, som for de ulike prisområdene strekker seg fra mai 2025 og frem til i dag.

Tabell 3: Modellens prediksjonsevne i testsettet

Prissone	MSE	R^2
NO1	763.0732	0.5274
NO2	555.9463	0.6040
NO3	2338.7337	−0.2656
NO4	869.6404	0.2602
NO5	1252.3460	0.2365

Som vist i Tabell 3 har NO1 og NO2 R^2-verdier på henholdsvis 0,52 og 0,60, noe som indikerer at modellene forklarer en betydelig del av variasjonen i strømprisene. Dette gjenspeiles i Figur 4, der de predikerte prisene i stor grad følger de observerte prisene i disse områdene. For NO4 og NO5 predikerer modellene derimot priser nær gjennomsnittet og fanger i liten grad opp svingningene i markedet. NO3 har en negativ R^2-verdi, som innebærer at modellen presterer dårligere enn en modell som alltid predikerer gjennomsnittsprisen i testperioden. Samlet tyder resultatene på at modellene har størst prediksjonsevne for NO1 og NO2, der europeiske strømpriser er inkludert som forklaringsvariabler.



Figur 4: Predikerte verdier mot observerte verdier

3.2 Regresjonskoeffisienter og sammenhenger

For å undersøke hvilke forklaringsvariabler som har sterkest sammenheng med strømprisen, ble de standardiserte regresjonskoeffisientene hentet ut fra hver modell. Koeffisientene viser hvordan

den predikerte strømprisen endres, målt i standardavvik, når en forklaringsvariabel øker med ett standardavvik, mens de øvrige variablene holdes konstante.

Figur X viser de estimerte standardiserte regresjonskoeffisientene for de ulike prisområdene. Figuren inkluderer også tilnærmede 95 prosent konfidensintervaller. Koeffisienter over null indikerer en positiv betinget sammenheng, mens koeffisienter under null indikerer en negativ betinget sammenheng. Konfidensintervallene gir informasjon om usikkerheten i koeffisientestimatene.

I prissone 3 begynte prisene å stige etter modellen var ferdig *Sett inn Figur X: Standardiserte regresjonskoeffisienter med tilnærmede 95 prosent konfidensintervaller.*

Figuren kan brukes til å undersøke om sammenhengene varierer mellom prisområdene. Siden NO1 og NO2 inkluderer europeisk strømpris, mens NO3–NO5 ikke gjør det, må sammenligninger av koeffisientene ta hensyn til at modellspesifikasjonene er forskjellige. Koeffisientene viser statistiske sammenhenger gitt variablene i modellen, og kan ikke uten videre tolkes som kausale effekter.

3.3 Observert og predikert strømpris

For å vurdere hvordan modellene følger den faktiske prisutviklingen, ble predikerte strømpriser sammenlignet med observerte priser i testperioden. Figur Y viser denne sammenligningen for NO3, mens Figur Z viser resultatene for alle fem prisområdene.

Sett inn Figur Y: Observert og predikert strømpris i NO3.

Sett inn Figur Z: Observert og predikert strømpris for alle prisområdene.

Disse figurene gjør det mulig å undersøke om modellene fanger opp den overordnede prisutviklingen, og om de klarer å følge perioder med store prisendringer. Avstanden mellom de observerte og predikerte kurvene illustrerer prediksjonsfeilene. Det bør særlig undersøkes om modellene systematisk undervurderer eller overvurderer høye pristopper, ettersom en lineær modell kan ha begrenset evne til å fange opp brå og ekstreme prisbevegelser.

3.4 Oppsummering av fremgangsmåten

Analysen følger dermed en trinnvis prosess der data fra flere kilder først ble sammenstilt og kontrollert, før forklaringsvariablene ble valgt og separate regresjonsmodeller ble estimert for hvert prisområde. Manglende observasjoner ble håndtert før dataene ble delt kronologisk i trenings- og testsett. Modellene ble estimert på treningsdataene, og prediksjonsevnen ble vurdert på senere observasjoner ved hjelp av RMSE, MAE og (R^2). Til slutt ble de standardiserte regresjonskoeffisientene og forholdet mellom observerte og predikerte priser undersøkt grafisk.

Denne fremgangsmåten gir grunnlag for å vurdere både hvilke variabler som har statistiske sammenhenger med strømprisen, og hvor godt modellene predikerer priser i testperioden. Resultatene må tolkes i lys av modellspesifikasjonene, tilgjengeligheten av data og at viktige faktorer som kan påvirke strømprisen, ikke nødvendigvis er inkludert.

Bibliografi

[1] SSB, «Hva koster det å produsere vannkraft?». [Online]. Tilgjengelig på: https://www.ssb.no/energi-og-industri/energi/statistikk/elektrisitetspriser